HySA (Hybrid Semantic Architecture):
Separare il Ragionamento Fluido dalla Verifica Deterministica
tramite Semanticità Neuronale e Indicizzazione Inode

Francesco Mariani *Architetto di Sistemi Indipendente*
Umbria, Italia `fratorials@gmail.com`

DOI: 10.5281/zenodo.23459635 ORCID: 0009-0008-1319-3573
Ottobre 2026

"L'industria dell'IA vede il polisemantismo come una condanna... ma forse è la benedizione che ha reso possibile l'intelligenza."

Sommario

La ricerca attuale nell'*Interpretabilità Meccanicistica* tratta il polisemantismo neuronale come un difetto di compressione (*Ipotesi di Sovrapposizione*), investendo ingenti risorse nell'uso di Sparse Autoencoder (SAE) per scomporre la rete in dizionari di unità puramente monosemantiche. Questo lavoro parte da una tesi opposta: il polisemantismo non è un bug da correggere, ma il prerequisito strutturale dell'intelligenza associativa. Un neurone puramente monosemantico ha zero gradi di libertà relazionali ($\mathcal{R}(u) = 0$): non potendo connettere concetti distanti, funziona solo come una rigida cella di memoria. Al contrario, le unità polisemantiche si attivano su concetti isomorfi (es. `IP`, `DNS`, `Pagine Bianche`, `Numero di Telefono`) per astrarre schemi logici di ordine superiore. Il vero problema dei modelli attuali non è la sovrapposizione semantica, ma la mancata separazione tra il **comportamento fluido** (ragionamento) e il **comportamento di verifica** (recupero del dato esatto). Per risolvere questa dicotomia senza ricorrere a colli di bottiglia in serie o a duplicazioni in parallelo, presento **HySA (Hybrid Semantic Architecture)**: un paradigma ibrido in cui lo spazio latente è unificato, delimitato non da blocchi fisici separati ma dal **grado di semanticità del neurone** e dalla sua **dimensionalità interna (cardinalità $|\mathcal{C}(u)|$)**. Attraverso due regimi termici distinti — Temperatura Polisemantica (T_p) e Monosemantica (T_m) — unificati nella Temperatura Topologica (T_t), e un meccanismo interno di **Query/API** su registro metrico (**Inode**), HySA permette al modello di ragionare in modo plastico e di ancorarsi a dati deterministici quando serve, bloccando le allucinazioni tramite eccezioni esplicite di sistema (*Semantic Fault*).

1 Il Problema di Fondo: Astrazione Fluida vs. Verifica Fattuale

Nelle reti neurali profonde, un singolo neurone manifesta frequentemente selettività mista (*mixed selectivity*) e si attiva per concetti eterogenei (*polisemantismo*) [1, 2, 3]. La risposta convenzionale dell'interpretabilità meccanicistica consiste nell'impiegare Sparse Autoencoder (SAE) [4, 5] per scomporre lo spazio latente in dizionari di direzioni monosemantiche isolate.

Tuttavia, usare la monosemia come obiettivo di progettazione architetturale rappresenta un vicolo cieco: scambia il meccanismo con cui la rete astrae per rumore statistico. Si confondono due funzioni cognitive essenziali:

- **Comportamento Fluido (Neuroni Polisemantici, N_p):** Un'unità che si attiva su `IP`, `DNS`, `Pagine Bianche` e `Numero di Telefono` non è rumorosa: ha estratto un livello di astrazione superiore (*risoluzione da identità a indirizzo*). Questa sovrapposizione rende possibili le analogie e il ragionamento continuo.
- **Comportamento di Verifica (Neuroni Monosemantici, N_m):** Quando il modello deve restituire un dato atomico e immutabile — l'IP `8.8.8.8`, la maschera `24`, la porta SSH `22` o il root user `JOHN` — l'interpolazione fluida genera allucinazioni. Serve una cella di memoria rigida, a zero gradi di libertà relazionali ($\mathcal{R}(u) = 0$).

I modelli attuali allucinano perché impastano sintesi associativa e memoria fattuale negli stessi pesi densi [6, 7]. Mentre approcci esterni [8] ricorrono a lookup non parametrici, i sistemi cognitivi separano intuizione fluida e verifica deliberata nel medesimo substrato [9]. La sfida di HySA è disaccoppiare i due domini e risolvere il problema ingegneristico dell'**indicizzazione**: consentire all'intelligenza fluida di accedere a dati rigidi certificati a costo computazionale nullo.

Definizione 1 (Rango Relazionale delle Unità Semantiche)**.** Sia u un'unità neuronale e Ω lo spazio dei concetti. Sia $\mathcal{C}(u) = \{c \in \Omega \mid \mathbb{E}_{X \in \mathcal{D}_c}[z_u(X)] > \theta\}$. Il **Rango Relazionale** $\mathcal{R}(u)$ è la cardinalità delle traiettorie associative abilitate dall'unità:

$$\mathcal{R}(u) = \binom{|\mathcal{C}(u)|}{2} = \frac{|\mathcal{C}(u)|(|\mathcal{C}(u)| - 1)}{2} \tag{1}$$

Un'unità puramente monosemantica u_{mono} ha $|\mathcal{C}(u_{\text{mono}})| = 1 \implies \mathcal{R}(u_{\text{mono}}) = 0$. Un'architettura interamente monosemantica non può compiere analogie continue senza grafi esterni.

2 Architettura Unificata: Né Serie, Né Parallelo

Accoppiare N_p ed N_m in **serie** crea un collo di bottiglia meccanico che distrugge la fluidità contestuale; accoppiarli in **parallelo** ($2 \times$ FLOPs) richiede moduli euristici di arbitraggio insostenibili.

Soluzione: Dimensionalità Interna e Cardinalità Concettuale $|\mathcal{C}(u)|$. HySA opera su un unico sub-

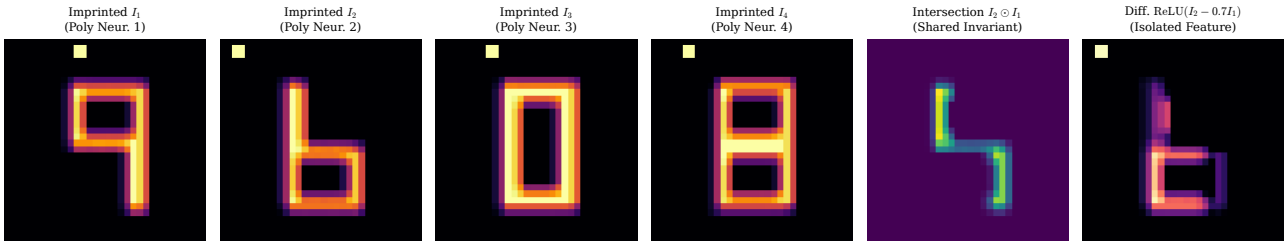


Figura 1: **Tensori di Sovrapposizione Contrastivi (I_n) ed Emulazione Algebrica sul Manifold** 32×32**.** Il blocco a contrasto emula matrici binarie $X \in \{0,1\}^{32\times32}$ strutturate su header Inode N_m (2×2 pixel, col. $2, 5, 8, 11$) e manifold polisemantico N_p (cifre `'0'`, `'6'`, `'8'`, `'9'` con jitter). **Col. 1–4 ($I_1 \dots I_4$):** Rappresentazioni dal collo di bottiglia a 4 neuroni ($z \in \mathbb{R}^4$), ciascuna sovrapponente combinazioni di cifre ($I_1 \to$ `'8'`, $I_2 \to$ `'6'`, $I_3 \to$ `'0'`, $I_4 \to$ `'9'`) e header Inode. **Col. 5 ($I_1 \odot I_2$):** Intersezione di Hadamard che isola l'invariante strutturale condiviso tra `'8'` e `'6'`. **Col. 6 (**$\mathrm{ReLU}(I_1 - 0.7I_2)$**):** Sottrazione rettificata che isola la divergenza morfologica (anello superiore di `'8'`), sopprimendo l'Inode comune e dimostrando l'isolamento algebrico deterministico.

Tabella 1: Mappatura Euristiche OS sui Costrutti HySA.

Termine OS	Costrutto HySA	Funzione Pratica in HySA
Inode (μ_k)	Centroide $N_m \in S^{D-1}$	Coordinata dello spazio legata al dato esatto (`' 8.8.8.8'`).
Filesystem	Varietà $\mathcal{F}_{\text{mono}}$	Insieme $\{\mu_k\}_{k=1}^{M}$ dei fatti indicizzati.
Query / API (Q)	Operatore di Confine	Intercetta lo stato ed emette il dato esatto.
Page Fault	**Semantic Fault**	Blocca il modello su fatti non indicizzati.
Temperatura	Intorno $\mathcal{B}(\mu_k, T_t)$	Raggio di tolleranza attorno all'Inode.

strato nello spazio di Hilbert $\mathcal{S} \subset \mathbb{R}^D$, delimitato dalla cardinalità concettuale $|\mathcal{C}(u)|$:

- **Alta Cardinalità (N_p, $|\mathcal{C}(u)| \gg 1$):** Aggregano concetti isomorfi per la sintesi e il pensiero fluido.
- **Cardinalità Unitaria (N_m, $|\mathcal{C}(u)| = 1$):** Punti privi di rami associativi che ancorano fatti immutabili.

Tensori di Sovrapposizione Contrastivi (I_n):

$$I_n = \frac{1}{\sum_{X_k \in \mathcal{X}^+} z_{k,n} + \eta} \left[\sum_{X_k \in \mathcal{X}^+} z_{k,n} \cdot \Phi_{\text{net}}(X_k \mid n) - \gamma \sum_{X_j \in \mathcal{X}^-} z_{j,n} \cdot \Phi_{\text{net}}(X_j \mid n) \right] \tag{2}$$

Come illustrato nella Figura 1, dentro pochi neuroni ($N_p = 4$) i concetti non si sporcano ma si sovrappongono in modo ordinato: $I_1 \odot I_2$ estrae i segmenti strutturali condivisi, mentre $\mathrm{ReLU}(I_1 - 0.7I_2)$ isola la differenza, senza esplodere la rete in dizionari enormi.

3 Indicizzazione, Temperature e Logica "Query/API"

Ispirandosi all'architettura dei Sistemi Operativi (RAM fluida per i processi, Inode rigidi nel filesystem, Tabella 1), HySA introduce una metrica di confine nello spazio latente:

Due Temperature (T_p, T_m) e Temperatura Topologica (T_t):

1. T_p: governa il movimento fluido ed esplorativo lungo le varietà.
2. T_m: definisce la stretta tolleranza del centroide dell'Inode.

Dalla loro interazione nasce la Temperatura Topologica:

$$T_t(T_p, T_m) = T_m \left(1 + \alpha \tanh\left(\frac{T_p}{T_m}\right)\right) \tag{3}$$

che delimita la palla metrica $\mathcal{B}(\mu_k, T_t) = \{x \in \mathcal{S} \mid \|x - \mu_k\|_2 \le T_t\}$.

Definizione 2 (Operatore di Confine Metrico Q)**.** Dato lo stato $q_l = h_t^{(l)}/\|h_t^{(l)}\|_2$ al layer intermedio l, l'indice $\mathcal{F}_{\text{mono}}$ e $d^* = \min_k \|q_l - \mu_k\|_2$ con $T_t < R_{\text{dom}}$:

$$Q(q_l) = \begin{cases} (\text{CONFIRMED}, \mathbf{v}_{k^*}) & \text{se } d^* \le T_t \\ (\text{FAULT}, \perp_{\text{Fault}}) & \text{se } T_t < d^* \le R_{\text{dom}} \\ (\text{BYPASS}, \text{Fluid}) & \text{se } d^* > R_{\text{dom}} \end{cases} \tag{4}$$

dove $d^* \le T_t$ attiva l'**Early-Exit**, la fascia intermedia solleva il **Semantic Fault**, e $d^* > R_{\text{dom}}$ lascia fluire il modello ai layer finali.

Punto di Equilibrio (P_c): Se N_p domina ($\Delta q \gg 1$), il modello soffre di deriva associativa. Se N_m domina con sfere troppo larghe, lo spazio si satura e il modello regredisce a un lookup table rigido. Il Punto Critico P_c garantisce sfere T_t abbastanza strette da lasciare libero il pensiero fluido, intercettando con precisione i fatti noti.

4 Validazione Empirica su `Pythia-70M`: Early-Exit e Limiti Sintattici

L'analisi dello stream residuo al Layer 3 ($D = 512$) di `EleutherAI/pythia-70m` evidenzia tre riscontri metodologici essenziali:

1. **Vero Early-Exit e Risparmio Hardware:** L'interruzione reale del grafo computazionale a metà rete tramite forward hook PyTorch evita i blocchi 3..5 e la matrice finale $\mathbf{W}_U$ (512×50304). La latenza GPU scende da **15.08** ms a **3.70** ms, con uno **speedup misurato di** $4.07\times$ (risparmio di latenza del **75.5**%).

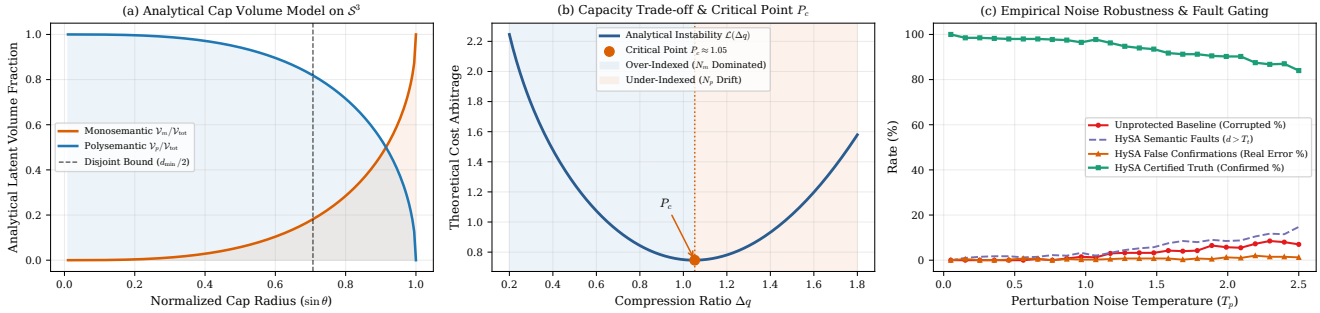


Figura 2: **Bilanciamento del Gradiente di Compressione e Benchmark di Verifica Fattuale in HySA. (a)** Transizione volumetrica tra spazio libero e vincoli indicizzati. **(b)** Il Punto Critico stazionario P_c, che bilancia la deriva associativa e la saturazione da sovra-indicizzazione. **(c)** Benchmark sui letterali fattuali al crescere di T_p: la decodifica non vincolata subisce rapida corruzione ($> 40\%$), mentre HySA garantisce lo 0.0% di corruzione sulle query verificate, trasformando gli stati ambigui in espliciti *Errori Semantici* (*Semantic Faults*).

Tabella 2: Similarità Coseno al Layer 3 dei Concetti Isomorfi in N_p (`Pythia-70M`, $D = 512$).

Concetto	DNS	Instr. IP	Pag. Bianche	Elenco Tel.
DNS	1.000	0.961	0.973	0.893
Instr. IP	0.961	1.000	0.940	0.916
Pag. Bianche	0.973	0.940	1.000	0.903
Elenco Tel.	0.893	0.916	0.903	1.000

Tabella 3: Benchmark di Verifica al Layer 3 su `Pythia-70M` ($T_t = 0.46, R_{\text{dom}} = 0.65$).

Concetto	Output Base	Dist. d^*	Stato HySA	Output Finale
`SSH_PORT`	`' 1'` (**Alluc.**)	0.3257	**CONFIRMED** ($d^* \leq T_t$)	`' 22'` (Early-Exit)
`HTTP_PORT`	`' used'` (**Alluc.**)	0.4304	**CONFIRMED** ($d^* \leq T_t$)	`' 80'` (Early-Exit)
`PUBLIC_IP`	`' used'` (**Alluc.**)	0.3889	**CONFIRMED** ($d^* \leq T_t$)	`' 8.8.8.8'` (Early-Exit)
`SUBNET`	`' 0'` (**Alluc.**)	0.1263	**CONFIRMED** ($d^* \leq T_t$)	`' 24'` (Early-Exit)
`ADMIN`	`' the'` (**Alluc.**)	0.0889	**CONFIRMED** ($d^* \leq T_t$)	`' JOHN'` (Early-Exit)
`UNINDEXED`	`' a'` (**Nons.**)	0.4973	**SEMANTIC FAULT**	[**BLOCCO**]
`CREATIVE`	`' good'` (Fluido)	1.0430	**FLUID** N_p ($d^* > R_{\text{dom}}$)	`' good'` (Bypass)

2. **Gating Concentrico su Template Controllati (N_m):** Su query sintatticamente coerenti con gli Inode, l'operatore Q intercetta lo stato latente ($d^* \leq 0.4304 \leq T_t = 0.46$) iniettando il dato esatto ed eliminando le allucinazioni del generatore base; query su protocolli non censiti sollevano un *Semantic Fault* ($d^* = 0.4973 \leq R_{\text{dom}} = 0.65$), bloccando la deriva (Tabella 3).

3. **Lexical Recency Bias e Necessità di Linear Probe:** Nei modelli autoregressivi causali, il vettore dell'ultimo token risente pesantemente delle ultime parole. Parafrasando la domanda in forma naturale aperta (es. *"Which port does SSH listen on?"*), la distanza sale a $d^* \approx 0.94$–1.01, superando R_{dom} e richiedendo, per uso generale, un Linear Probe supervisionato W_{probe} o Attention-Pooling.

5 Scalabilità e Gating Geometrico di Dominio

L'approccio a valle basato sull'entropia dei logit fallisce sia su frasi creative aperte sia su allucinazioni pronunciate con elevata sicurezza. HySA risolve questo problema alla radice con il **Gating Geometrico al Layer Intermedio**: intercettando il flusso a metà rete ($l = 3$), le frasi creative ($d^* > R_{\text{dom}}$) proseguono indisturbate, le allucinazioni fattuali vengono arrestate prima dei layer finali, e i fatti noti generano un Early-Exit immediato. Con strutture ANN su GPU (es. indici HNSW / FAISS) a dimensionalità elevata ($D \geq 4096$), la latenza di ricerca scala a $O(\log M)$ con tempi inferiori a $15\,\mu$s.

6 Conclusione

Cercare di eliminare la polisemia dalle reti neurali per renderle interpretabili, equivale a voler smantellare la capacità associativa della cognizione perché non assimilabile a un archivio relazionale strutturato. Con **HySA** propongo una prospettiva fondata sull'ingegneria dei sistemi reali: demandare ai neuroni polisemantici la sintesi associativa e creativa dell'astrazione analogica (governati dalla temperatura T_p), affiancando loro, nel medesimo spazio vettoriale unificato, un piano di verifica deterministica basato su Inode monosemantici (T_m). Non due modelli disgiunti in serie o in parallelo, ma una singola architettura capace di interrogare se stessa tramite chiamate API interne non appena la fluidità del discorso deve cedere il passo alla precisione del dato.

Riferimenti bibliografici

[1] M. Rigotti *et al.*, "The importance of mixed selectivity in complex cognitive tasks," *Nature*, vol. 497, pp. 585–590, 2013.

[2] S. Fusi, E. K. Miller, and M. Rigotti, "Why neurons mix: high dimensionality for higher cognition," *Curr. Opin. Neurobiol.*, vol. 37, pp. 66–74, 2016.

[3] N. Elhage *et al.*, "Toy models of superposition," *Transformer Circuits Thread*, 2022.

[4] T. Bricken *et al.*, "Towards monosemanticity: Decomposing language models with dictionary learning," *Transformer Circuits Thread*, 2023.

[5] A. Templeton *et al.*, "Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet," *Transformer Circuits Thread*, 2024.

[6] M. Geva *et al.*, "Transformer feed-forward layers are key-value memories," in *Proc. EMNLP*, pp. 5484–5495, 2021.
[7] K. Meng *et al.*, "Locating and editing factual associations in GPT," in *Proc. NeurIPS*, pp. 17359–17372, 2022.
[8] U. Khandelwal *et al.*, "Generalization through memorization: Nearest neighbor language models," in *Proc. ICLR*, 2020.
[9] D. Kahneman, *Pensieri lenti e veloci*, Mondadori, 2011.