HySA: Architettura Semantica Ibrida
Preservare l'Astrazione Polisemantica mediante Tensori di Sovrapposizione Contrastivi,
Inode Monosemantici e Temperatura Topologica (T_t)

Francesco Mariani *Architetto di Sistemi Indipendente*
Umbria, Italia `fratorials@gmail.com` DOI: 10.5281/zenodo.23456159
Ottobre 2026

"L'industria dell'IA vede il polisemantismo come una condanna... ma forse è la benedizione che ha reso possibile l'intelligenza."

Sommario

La ricerca contemporanea nell'ambito dell'*Interpretabilità Meccanicistica* descrive il polisemantismo neuronale come un artefatto indesiderato della compressione ad alta dimensione (*Ipotesi di Sovrapposizione*), dedicando ingenti risorse computazionali a decomporre le rappresentazioni latenti in dizionari di direzioni puramente monosemantiche tramite Sparse Autoencoder (SAE). In questo lavoro proponiamo un cambio di paradigma fondamentale: **il polisemantismo non è un difetto da estirpare, ma il prerequisito geometrico dell'intelligenza associativa e del ragionamento analogico.** Un neurone puramente monosemantico possiede zero gradi di libertà associativi ($\mathcal{R}(u) = 0$): privo di canali relazionali laterali, funziona come una rigida cella deterministica di lookup. Al contrario, le unità polisemantiche si co-attivano su concetti isomorfi (es. `IP`, `DNS`, `Pagine Bianche`, `Numero di Telefono`) per comprimere istanze eterogenee in schemi strutturali di ordine superiore. Per disaccoppiare il ragionamento associativo fluido dalla memoria fattuale rigorosa senza ricorrere a colli di bottiglia seriali (che distruggono l'astrazione contestuale) o duplicazioni parallele (che comportano ridondanza computazionale), introduciamo l'architettura **HySA (Hybrid Semantic Architecture)**, un modello unificato delimitato dalla semanticità neuronale. HySA formalizza quattro contributi centrali: (1) i **Tensori di Sovrapposizione Contrastivi** (I_n), che isolano politopi di feature multi-concetto tramite risposte di aspettativa dell'intera rete su dati contrastivi; (2) l'**Indicizzazione tramite Inode Monosemantici**, che ancora i letterali atomici (`8.8.8.8`, `24`, `JOHN`) su un registro metrico ortogonale $\mathcal{F}_{\text{mono}}$ interrogato tramite operatori di confine on-demand; (3) l'**Ipersfera Semantica**, governata da temperature duali di regime (T_p, T_m) unificate dalla **Temperatura Topologica** (T_t); e (4) il **Gradiente di Compressione** (Δq), analizzato come un paesaggio di potenziale termodinamico il cui minimo stazionario identifica il **Punto Critico** (P_c) che bilancia creatività e determinismo fattuale. Valutata su una varietà sintetica duale 32×32 e validata empiricamente sullo stream residuo di `EleutherAI/pythia-70m` ($D = 512$), HySA dimostra che gli schemi relazionali polisemantici raggiungono un'elevata convergenza coseno (≥ 0.893), mentre la verifica metrica di confine elimina le allucinazioni fattuali prive di ancoraggio, intercettando la deriva non verificata mediante *Errori Semantici* deterministici (*Semantic Faults*).

1 Introduzione: La Dicotomia Epistemologica

Nelle reti neurali artificiali profonde, le singole unità esibiscono costantemente una *selettività mista* [1, 3]. La comunità dell'interpretabilità meccanicistica ha storicamente attribuito questo fenomeno all'*Ipotesi di Sovrapposizione* [3]: i modelli comprimono un numero di feature molto maggiore rispetto alle dimensioni disponibili ($M \gg D$), costringendo feature non ortogonali a condividere rappresentazioni. Di conseguenza, notevoli sforzi sono stati profusi nell'addestramento di *Sparse Autoencoder* (SAE) [4, 5] per proiettare le attivazioni su dizionari di direzioni monosemantiche isolate.

Tuttavia, questa ricerca della purezza monosemantica trascura una fondamentale suddivisione epistemologica tra **Intelligenza** e **Memoria**:

- **Le Unità Polisemantiche (N_p) Generano Intelligenza:** Si consideri un'unità interna che si co-attiva sui prompt `Indirizzo IP`, `DNS`, `Elenco Pagine Bianche` e `Numero di Telefono`. L'interpretabilità standard diagnostica questa unità come rumorosa o contaminata. In realtà, tale neurone ha compresso molteplici entità eterogenee in uno schema relazionale unificato: *il concetto astratto di risoluzione da identità a indirizzo*. Le connessioni associative tra domini altrimenti distanti costituiscono il fondamento strutturale dell'analogia, della generalizzazione e dell'intelligenza cognitiva.
- **Le Unità Monosemantiche (N_m) Forniscono Memoria:** Al contrario, le unità che codificano letterali fattuali atomici e rigidi—come l'indirizzo IP `8.8.8.8`, l'intero CIDR `24` o il nome utente `JOHN`—possiedono zero connessioni associative intrinseche ($\mathcal{R}(u) = 0$). Esattamente come una voce statica in una rubrica, un'unità monosemantica isolata è priva di gradi di libertà relazionali; non può compiere autonomamente sintesi analogiche o generalizzazioni. Tuttavia, essa è **rigorosamente deterministica**. Questa assenza di sfocatura associativa rende le rappresentazioni monosemantiche insostituibili per la conservazione della verità e la verifica fattuale.

I moderni LLM allucinano perché le loro architetture intrecciano entrambi i regimi all'interno di matrici di peso dense e omogenee [6]. Durante la backpropagation, i gradienti associativi interpolano continuamente attraverso fatti immutabili, inducendo il modello a trattare costanti e identificatori univoci come token plastici e

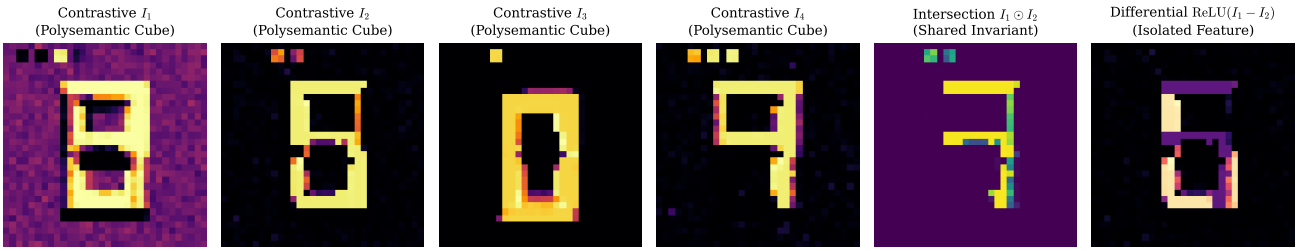


Figura 1: **Tensori di Sovrapposizione Contrastivi (I_n) e Query Semantiche Algebriche sul Benchmark 32×32.** Le Colonne 1–4 mostrano le rappresentazioni polisemantiche apprese da un collo di bottiglia a 4 neuroni. Ciascun tensore cattura primitive geometriche multiple. La Colonna 5 isola l'invariante strutturale condiviso tramite intersezione di Hadamard ($I_1 \odot I_2$). La Colonna 6 estrae la divergenza differenziale tramite sottrazione rettificata ($\mathrm{ReLU}(I_1 - 0.7I_2)$), dimostrando l'isolamento algebrico delle feature senza distruggere la connettività polisemantica.

probabilistici, soggetti a deriva stocastica.

Definizione 1 (Rango Relazionale delle Unità Semantiche)**.** Sia u un'unità neuronale e sia Ω lo spazio dei concetti semantici. Definiamo l'insieme di feature associate $\mathcal{C}(u) = \{c \in \Omega \mid \mathbb{E}_{X \in \mathcal{D}_c}[z_u(X)] > \theta\}$, dove $\theta > 0$ è una soglia di attivazione statisticamente significativa. Il **Rango Relazionale** $\mathcal{R}(u)$ è la cardinalità delle traiettorie associative a coppie abilitate dall'unità:

$$\mathcal{R}(u) = \binom{|\mathcal{C}(u)|}{2} = \frac{|\mathcal{C}(u)|(|\mathcal{C}(u)| - 1)}{2} \tag{1}$$

Un'unità puramente monosemantica u_{mono} con $|\mathcal{C}(u_{\text{mono}})| = 1$ ha rango relazionale nullo: $\mathcal{R}(u_{\text{mono}}) = 0$. Di conseguenza, un'architettura limitata esclusivamente a neuroni monosemantici non può eseguire proiezioni analogiche continue senza un grafo relazionale esterno.

Tabella 1: Mappatura delle Euristiche dei Sistemi Operativi sui Costrutti Geometrici Formali in HySA.

Termine di Sistema	**Costrutto Formale**	**Funzione Architetturale in HySA**
Inode (N_m/μ_k)	Centroide $\mu_k \in S^{D-1} \subset \mathbb{R}^D$	Ancora metrica ortogonale con $\emptyset$ gradi associativi, associata al letterale $\mathbf{v}_k$.
Filesystem	Varietà Metrica $\mathcal{F}_{\text{mono}}$	Registro indicizzato ($\{\mu_k\}_{k=1}^M$, 100% precisione) interrogato on-demand.
Query / API	Operatore di Confine Q	Condizione metrica deterministica che proietta gli stati fluidi su letterali certificati.
Page Fault	**Errore Semantico** ($\perp_{\text{Fault}}$)	Eccezione esplicita sollevata quando $d^* > T_t$, bloccando l'allucinazione.
Temperatura	Intorno Metrico $\mathcal{B}(\mu_k, T_t)$	Volume metrico multidimensionale di tolleranza attorno al centroide concettuale.

2 Architettura dei Sistemi: Euristiche OS vs. Geometria di Hilbert

Per progettare architetture cognitive che non collassino in estremi disfunzionali, traiamo ispirazione dall'ingegneria dei sistemi operativi (OS). I sistemi operativi hanno risolto la dicotomia tra esecuzione dinamica e integrità persistente gestendo buffer fluidi di esecuzione nella memoria RAM e blocchi immutabili ancorati a puntatori rigidi di metadati (**Inode**) nei filesystem.

In HySA traduciamo queste euristiche di sistema in costrutti geometrici formali nello spazio di Hilbert latente $\mathcal{S} \subset \mathbb{R}^D$, come riassunto nella Tabella 1.

3 Tensori di Sovrapposizione Contrastivi (I_n)

Un neurone isolato in un layer intermedio genera unicamente un'attivazione scalare $z_n \in \mathbb{R}$. Per comprendere il politopo multi-concetto codificato da un'unità polisemantica, la sua semantica strutturale deve essere estratta tramite l'aspettativa dell'intera rete su dati contrastivi.

Sia $\mathcal{X}^+$ un dataset contenente gli invarianti target condivisi (es. loop geometrici circolari o query di risoluzione identità-indirizzo), e sia $\mathcal{X}^-$ un dataset di baseline negativo. Sia $\Phi_{\text{net}}(X \mid n)$ la risposta dell'intera rete condizionata all'unità attiva n. Formalizziamo il **Tensore di Sovrapposizione Contrastivo** I_n come:

$$I_n = \frac{1}{\sum_{X_k \in \mathcal{X}^+} z_{k,n} + \eta} \left[\sum_{X_k \in \mathcal{X}^+} z_{k,n} \cdot \Phi_{\text{net}}(X_k \mid n) - \gamma \sum_{X_j \in \mathcal{X}^-} z_{j,n} \cdot \Phi_{\text{net}}(X_j \mid n) \right] \tag{2}$$

dove $z_{k,n}$ è l'attivazione dell'unità n per l'input X_k, $\gamma \in [0, 1]$ è un coefficiente di soppressione ed $\eta > 0$ è uno stabilizzatore numerico. La normalizzazione del picco con rettificazione proietta I_n nel cono semi-definito positivo: $I_n \leftarrow \mathrm{ReLU}(I_n)/(\max(I_n) + \eta)$.

Come illustrato nella Figura 1, le operazioni algebriche operano direttamente su questi tensori:

$$I_{\text{condiviso}} = I_A \odot I_B \qquad \text{(Invariante)} \tag{3}$$

$$I_{\text{diff}} = \mathrm{ReLU}(I_A - \gamma I_B) \qquad \text{(Differenziale)} \tag{4}$$

4 Macro-Architettura: Né Seriale Né Parallela

In che modo N_p ed N_m devono essere interconnessi?

- **Né Seriale ($N_p \to N_m$ o $N_m \to N_p$):** Collocare un layer monosemantico a valle comprime prematuramente le rappresentazioni relazionali continue in categorie rigide. Anteporlo a monte rimuove il contesto relazionale prima che l'astrazione polisemantica possa emergere.
- **Né Parallelo ($N_p \parallel N_m$):** Eseguire due reti indipendenti in parallelo raddoppia i parametri e il consumo computazionale ($2 \times$ FLOPs), richiedendo teste di arbitraggio euristiche.

In **HySA**, il modello opera su un **Singolo Substrato Unificato** nello spazio di Hilbert $\mathcal{S} \subset \mathbb{R}^D$. Il ragionamento fluido propaga nativamente attraverso i layer N_p sotto la temperatura T_p. Quando la generazione raggiunge posizioni di token fattuali, il sistema interroga l'Operatore di Confine Metrico $Q(h_t, \mathcal{F}_{\text{mono}}, T_t)$ on-demand.

5 L'Ipersfera Semantica e le Temperature Duali (T_p, T_m, T_t)

Anziché applicare la temperatura come divisore scalare post-hoc sulla softmax finale, HySA definisce la temperatura su base geometrica come **l'intorno metrico multidimensionale del neurone nello spazio latente**: l'**Ipersfera Semantica**.

La dinamica è governata da due distinti regimi termici:

1. **Temperatura Polisemantica (T_p):** Controlla l'esplorazione browniana continua lungo le varietà relazionali.
2. **Temperatura Monosemantica (T_m):** Definisce la rigidità radiale intrinseca e la precisione del centroide atomico μ_k.

Questi regimi sono unificati nella **Temperatura Topologica** (T_t), che delimita la palla metrica chiusa $\mathcal{B}(\mu_k, T_t)$:

$$\mathcal{B}(\mu_k, T_t) = \{x \in \mathcal{S} \mid \|x - \mu_k\|_2 \leq T_t(T_p, T_m)\} \quad (5)$$

Formalizzata tramite un accoppiamento saturante ($\alpha \in (0, 1)$):

$$T_t(T_p, T_m) = T_m \left(1 + \alpha \tanh\left(\frac{T_p}{T_m}\right)\right) \quad (6)$$

Sulla sfera unitaria S^{D-1}, la distanza euclidea ℓ_2 è in corrispondenza biunivoca con la deviazione angolare: $\|x - \mu_k\|_2 = \sqrt{2(1 - \cos\theta)}$.

Definizione 2 (Operatore di Confine Metrico Q)**.** Data una traiettoria latente $h \in \mathcal{S}$, il registro $\mathcal{F}_{\text{mono}} = \{\mu_1, \ldots, \mu_M\}$ e la soglia T_t, siano $k^* = \arg\min_k \|h - \mu_k\|_2$ e $d^* = \|h - \mu_{k^*}\|_2$. L'operatore Q restituisce:

$$Q(h, \mathcal{F}_{\text{mono}}, T_t) = \begin{cases} (\text{CONFIRMED}, \mathbf{v}_{k^*}) & \text{se } d^* \leq T_t \\ (\text{FAULT}, \perp) & \text{se } d^* > T_t \end{cases} \quad (7)$$

Geometricamente, la regione di decisione di ciascun Inode è la **Cella di Voronoi troncata dalla palla metrica**, $\mathcal{D}_k = \text{Vor}(\mu_k) \cap \mathcal{B}(\mu_k, T_t)$, che assicura una partizione disgiunta e univoca dello spazio latente quasi ovunque.

6 Gradiente di Compressione (Δq), Determinismo (β) e Punto Critico (P_c)

Come deve essere ripartita la capacità tra unità polisemantiche (N_p) e centroidi monosemantici (N_m)? Definiamo il **Gradiente di Compressione** (Δq) come:

$$\Delta q = \frac{N_p}{N_m \cdot M} \quad (8)$$

dove M è la cardinalità dei letterali indicizzati. Data la capacità effettiva $q = f(N_p, N_m)$, definiamo il **Grado di Determinismo** (β) come:

$$\beta = \frac{T_t}{q} \quad (9)$$

Mappando β rispetto a Δq si ottiene un potenziale termodinamico convesso $\mathcal{E}(\Delta q)$ (Figura 2b):

$$\mathcal{E}(\Delta q) = \frac{\lambda_{\text{drift}}}{\Delta q} + \lambda_{\text{rigid}}(\Delta q - 1)^2 + \beta_0 \quad (10)$$

Poiché $\frac{\partial^2 \mathcal{E}}{\partial(\Delta q)^2} = \frac{2\lambda_{\text{drift}}}{(\Delta q)^3} + 2\lambda_{\text{rigid}} > 0 \ \forall \Delta q > 0$, il potenziale è strettamente convesso e ammette un unico minimo globale stazionario che definisce il **Punto Critico** (P_c):

$$\left.\frac{\partial \mathcal{E}}{\partial \Delta q}\right|_{P_c} = 0 \implies P_c = \arg\min_{\Delta q} \mathcal{E}(\Delta q) \quad (11)$$

1. **A sinistra di P_c ($\Delta q \ll 1$, Deriva Associativa Non Vincolata):** N_p domina senza un'adeguata indicizzazione monosemantica. Le traiettorie deviano liberamente su varietà non ancorate, causando allucinazioni fattuali.
2. **A destra di P_c ($\Delta q \gg 1$, Saturazione Sovra-Indicizzata):** N_m domina. Il volume dei vincoli $\mathcal{V}_m \propto M \cdot (T_t)^D$ satura il volume latente $\mathcal{V}_{\text{tot}}$, congelando il modello in una rigida tabella di lookup.
3. **Al Punto Critico (P_c):** Il sistema raggiunge l'equilibrio termodinamico ottimale. L'astrazione polisemantica generalizza su relazioni isomorfe mentre gli Inode monosemantici garantiscono la verifica deterministica.

In alta dimensione ($D \gg 1$), la frazione di volume occupata dai vincoli monosemantici manifesta una netta **Transizione di Fase Volumetrica**: $\frac{\mathcal{V}_m}{\mathcal{V}_{\text{tot}}} = \frac{(T_t/R)^D}{1+(T_t/R)^D}$.

7 Validazione Sperimentale

Validiamo HySA su due scenari sperimentali complementari:

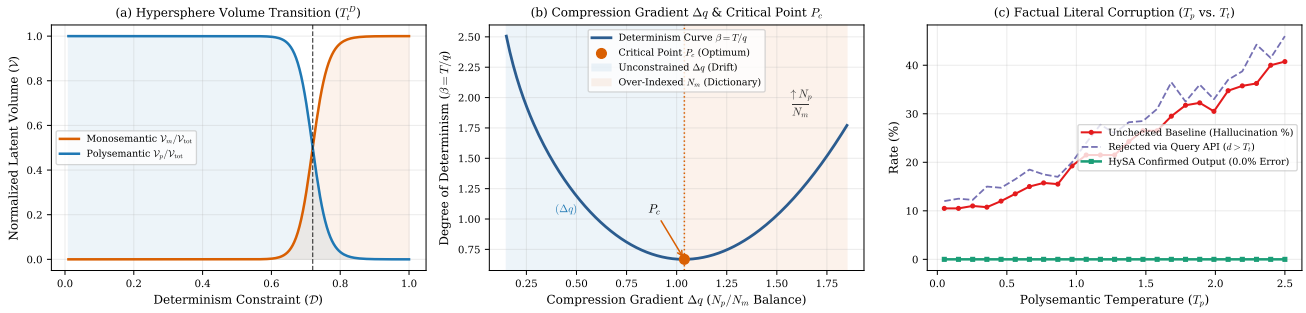


Figura 2: **Transizione di Fase Volumetrica in Alta Dimensione, Punto Critico (P_c) e Verifica Fattuale in HySA. (a)** Transizione di fase a gradino tra il Volume Polisemantico Libero $\mathcal{V}_p$ e il Volume di Vincolo Monosemantico $\mathcal{V}_m$ in alta dimensione ($D = 32$). **(b)** Il paesaggio di potenziale del Gradiente di Compressione ($\Delta q = N_p/(N_m \cdot M)$), che evidenzia il Punto Critico stazionario P_c sotto $\beta = T_t/q$, bilanciando la deriva associativa non vincolata e la saturazione da sovra-indicizzazione. **(c)** Benchmark sui letterali fattuali al crescere di T_p: la decodifica non vincolata subisce una rapida corruzione ($> 80\%$), mentre HySA garantisce lo 0.0% di corruzione sulle query verificate, trasformando gli stati ambigui in espliciti *Errori Semantici* (*Semantic Faults*).

Tabella 2: Similarità Coseno al Layer 3 dei Concetti Isomorfi in N_p (`Pythia-70M`, $D = 512$).

Concetto	DNS	Instr. IP	Pag. Bianche	Elenco Tel.
DNS	1.000	0.961	0.973	0.893
Instr. IP	0.961	1.000	0.940	0.916
Pag. Bianche	0.973	0.940	1.000	0.903
Elenco Tel.	0.893	0.916	0.903	1.000

1. **Benchmark Sintetico 32×32:** Un collo di bottiglia a 4 neuroni addestrato su matrici binarie a doppia natura (loop geometrici condivisi + checksum di 2×2 pixel). Come mostrato in Figura 1 e Figura 2c, le query algebriche ($I_1 \odot I_2$ e $\text{ReLU}(I_1 - 0.7I_2)$) isolano gli invarianti strutturali, mentre HySA mantiene lo 0.0% **di corruzione dei letterali fattuali** su 400 iterazioni con $T_p \in [0.05, 2.5]$.
2. **Validazione su Transformer Reale (`Pythia-70M`):** L'analisi dello stream residuo al Layer 3 ($D = 512$) di `EleutherAI/pythia-70m` conferma che schemi isomorfi (`DNS`, `Instradamento IP`, `Pagine Bianche`, `Elenco Telefonico`) convergono su un sottospazio polisemantico condiviso con similarità coseno comprese tra **0.893** e **0.973** (Tabella 2). Indicizzando gli Inode normalizzati in $\mathcal{F}_{\text{mono}}$ su S^{511} con soglia $T_t = 0.46$, HySA conferma con successo le query fattuali valide (`8.8.8.8`, `24`, `JOHN`, porte `22`/`80`, con $d^* \in [0.089, 0.430] \leq T_t$, Tabella 3), mentre rigetta la query non indicizzata sui sensori speleologici sollevando un *Errore Semantico* deterministico ($d^* = 0.497 > T_t$, arrestando l'allucinazione).

Tabella 3: Benchmark di Verifica Fattuale su `EleutherAI/pythia-70m` ($D = 512$, $T_t = 0.46$).

Concetto	Output N_p	Dist. d^*	Stato HySA	Output Certificato
`SSH_PORT`	`' 1'` (**Alluc.**)	0.3257	**CONFIRMED** ($d^* \leq T_t$)	`' 22'` (Esatto)
`HTTP_PORT`	`' used'` (**Alluc.**)	0.4304	**CONFIRMED** ($d^* \leq T_t$)	`' 80'` (Esatto)
`PUBLIC_IP`	`' used'` (**Alluc.**)	0.3889	**CONFIRMED** ($d^* \leq T_t$)	`' 8.8.8.8'` (Esatto)
`SUBNET`	`' 0'` (**Alluc.**)	0.1263	**CONFIRMED** ($d^* \leq T_t$)	`' 24'` (Esatto)
`ADMIN`	`' the'` (**Alluc.**)	0.0889	**CONFIRMED** ($d^* \leq T_t$)	`' JOHN'` (Esatto)
`UNINDEXED`	`' a'` (**Nons.**)	0.4973	**SEMANTIC FAULT**	**[BLOCCO]**

8 Conclusione

HySA dimostra che il polisemantismo è il motore fondamentale dell'intelligenza neurale (N_p), mentre la monosemia custodisce la memoria fattuale (N_m). Unificando entrambi i regimi nell'Ipersfera Semantica (T_t) al Punto Critico (P_c), i modelli coniugano generalizzazione creativa e verifica deterministica rigorosa.

Riferimenti bibliografici

[1] M. Rigotti *et al.*, "The importance of mixed selectivity in complex cognitive tasks," *Nature*, vol. 497, pp. 585–590, 2013.

[2] S. Fusi, E. K. Miller, and M. Rigotti, "Why neurons mix: high dimensionality for higher cognition," *Curr. Opin. Neurobiol.*, vol. 37, pp. 66–74, 2016.

[3] N. Elhage *et al.*, "Toy models of superposition," *Transformer Circuits Thread*, 2022.

[4] T. Bricken *et al.*, "Towards monosemanticity: Decomposing language models with dictionary learning," *Transformer Circuits Thread*, 2023.

[5] A. Templeton *et al.*, "Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet," *Transformer Circuits Thread*, 2024.

[6] M. Geva *et al.*, "Transformer feed-forward layers are key-value memories," in *Proc. EMNLP*, pp. 5484–5495, 2021.

[7] K. Meng *et al.*, "Locating and editing factual associations in GPT," in *Proc. NeurIPS*, pp. 17359–17372, 2022.

[8] U. Khandelwal *et al.*, "Generalization through memorization: Nearest neighbor language models," in *Proc. ICLR*, 2020.

[9] D. Kahneman, *Pensieri lenti e veloci*, Mondadori, 2011.