# HySA: Architettura Semantica Ibrida
## Preservare l'Astrazione Polisemantica mediante Tensori di Sovrapposizione Contrastivi,
## Inode Monosemantici e Temperatura Topologica ($T_t$)

**Francesco Mariani** *Architetto di Sistemi Indipendente*
Umbria, Italia `fratorials@gmail.com` DOI: 10.5281/zenodo.23459635
Ottobre 2026

*"L'industria dell'IA vede il polisemantismo come una condanna... ma forse è la benedizione che ha reso possibile l'intelligenza."*

**Sommario**

La ricerca contemporanea nell'ambito dell'*Interpretabilità Meccanicistica* descrive il polisemantismo neuronale come un artefatto indesiderato della compressione ad alta dimensione (*Ipotesi di Sovrapposizione*), dedicando ingenti risorse computazionali a decomporre le rappresentazioni latenti in dizionari di direzioni puramente monosemantiche tramite Sparse Autoencoder (SAE). In questo lavoro proponiamo un cambio di paradigma fondamentale: **il polisemantismo non è un difetto da estirpare, ma il prerequisito geometrico dell'intelligenza associativa e del ragionamento analogico.** Un neurone puramente monosemantico possiede zero gradi di libertà associativi ($\mathcal{R}(u) = 0$): privo di canali relazionali laterali, funziona come una rigida cella deterministica di lookup. Al contrario, le unità polisemantiche si co-attivano su concetti isomorfi (es. `IP`, `DNS`, `Pagine Bianche`, `Numero di Telefono`) per comprimere istanze eterogenee in schemi strutturali di ordine superiore. Per disaccoppiare il ragionamento associativo fluido dalla memoria fattuale rigorosa senza ricorrere a colli di bottiglia seriali (che distruggono l'astrazione contestuale) o duplicazioni parallele (che comportano ridondanza computazionale), introduciamo l'architettura **HySA (Hybrid Semantic Architecture)**, un modello unificato delimitato dalla semanticità neuronale. HySA formalizza quattro contributi centrali: (1) i **Tensori di Sovrapposizione Contrastivi** ($I_n$), che isolano politopi di feature multi-concetto tramite risposte di aspettativa dell'intera rete su dati contrastivi; (2) l'**Indicizzazione tramite Inode Monosemantici**, che ancora i letterali atomici (`8.8.8.8`, `24`, `JOHN`) su un registro metrico ortogonale $\mathcal{F}_{\text{mono}}$ interrogato tramite operatori di confine on-demand; (3) l'**Ipersfera Semantica**, governata da temperature duali di regime ($T_p, T_m$) unificate dalla **Temperatura Topologica** ($T_t$); e (4) il **Gradiente di Compressione** ($\Delta q$), analizzato come un paesaggio di potenziale termodinamico il cui minimo stazionario identifica il **Punto Critico** ($P_c$) che bilancia creatività e determinismo fattuale. Valutata su una varietà sintetica duale $32 \times 32$ e validata empiricamente sullo stream residuo di `EleutherAI/pythia-70m` ($D = 512$), HySA dimostra che gli schemi relazionali polisemantici raggiungono un'elevata convergenza coseno ($\geq 0.893$), mentre la verifica metrica di confine elimina le allucinazioni fattuali prive di ancoraggio, intercettando la deriva non verificata mediante *Errori Semantici* deterministici (*Semantic Faults*).

# 1 Introduzione: La Dicotomia Epistemologica

Nelle reti neurali artificiali profonde, le singole unità esibiscono costantemente una *selettività mista* [1, 3]. La comunità dell'interpretabilità meccanicistica ha storicamente attribuito questo fenomeno all'*Ipotesi di Sovrapposizione* [3]: i modelli comprimono un numero di feature molto maggiore rispetto alle dimensioni disponibili ($M \gg D$), costringendo feature non ortogonali a condividere rappresentazioni. Di conseguenza, notevoli sforzi sono stati profusi nell'addestramento di *Sparse Autoencoder* (SAE) [4, 5] per proiettare le attivazioni su dizionari di direzioni monosemantiche isolate.

Tuttavia, questa ricerca della purezza monosemantica trascura una fondamentale suddivisione epistemologica tra **Intelligenza** e **Memoria**:

- **Le Unità Polisemantiche ($N_p$) Generano Intelligenza:** Si consideri un'unità interna che si co-attiva sui prompt `Indirizzo IP`, `DNS`, `Elenco Pagine Bianche` e `Numero di Telefono`. L'interpretabilità standard diagnostica questa unità come rumorosa o contaminata. In realtà, tale neurone ha compresso molteplici entità eterogenee in uno schema relazionale unificato: *il concetto astratto di risoluzione da identità a indirizzo*. Le connessioni associative tra domini altrimenti distanti costituiscono il fondamento strutturale dell'analogia, della generalizzazione e dell'intelligenza cognitiva.
- **Le Unità Monosemantiche ($N_m$) Forniscono Memoria:** Al contrario, le unità che codificano letterali fattuali atomici e rigidi—come l'indirizzo IP `8.8.8.8`, l'intero CIDR `24` o il nome utente `JOHN`—possiedono zero connessioni associative intrinseche ($\mathcal{R}(u) = 0$). Esattamente come una voce statica in una rubrica, un'unità monosemantica isolata è priva di gradi di libertà relazionali; non può compiere autonomamente sintesi analogiche o generalizzazioni. Tuttavia, essa è **rigorosamente deterministica**. Questa assenza di sfocatura associativa rende le rappresentazioni monosemantiche insostituibili per la conservazione della verità e la verifica fattuale.

I moderni LLM allucinano perché le loro architetture intrecciano entrambi i regimi all'interno di matrici di peso dense e omogenee [6]. Durante la backpropagation, i gradienti associativi interpolano continuamente attraverso fatti immutabili, inducendo il modello a trattare costanti e identificatori univoci come token plastici e

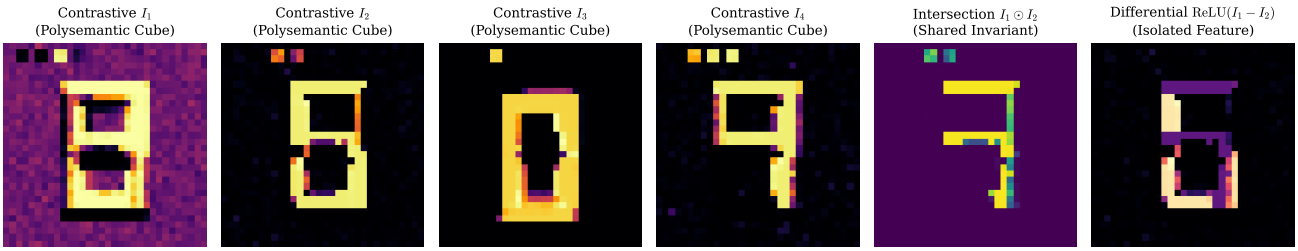



Figura 1: **Tensori di Sovrapposizione Contrastivi ($I_n$) e Query Semantiche Algebriche sul Benchmark $32 \times 32$.** Le Colonne 1–4 mostrano le rappresentazioni polisemantiche apprese da un collo di bottiglia a 4 neuroni. Ciascun tensore cattura primitive geometriche multiple. La Colonna 5 isola l'invariante strutturale condiviso tramite intersezione di Hadamard ($I_1 \odot I_2$). La Colonna 6 estrae la divergenza differenziale tramite sottrazione rettificata ($\mathrm{ReLU}(I_1 - 0.7I_2)$), dimostrando l'isolamento algebrico delle feature senza distruggere la connettività polisemantica.

probabilistici, soggetti a deriva stocastica.

**Definizione 1** (Rango Relazionale delle Unità Semantiche)**.** Sia $u$ un'unità neuronale e sia $\Omega$ lo spazio dei concetti semantici. Definiamo l'insieme di feature associate $\mathcal{C}(u) = \{c \in \Omega \mid \mathbb{E}_{X \in \mathcal{D}_c}[z_u(X)] > \theta\}$, dove $\theta > 0$ è una soglia di attivazione statisticamente significativa. Il **Rango Relazionale** $\mathcal{R}(u)$ è la cardinalità delle traiettorie associative a coppie abilitate dall'unità:

$$\mathcal{R}(u) = \binom{|\mathcal{C}(u)|}{2} = \frac{|\mathcal{C}(u)|(|\mathcal{C}(u)| - 1)}{2} \tag{1}$$

Un'unità puramente monosemantica $u_{\text{mono}}$ con $|\mathcal{C}(u_{\text{mono}})| = 1$ ha rango relazionale nullo: $\mathcal{R}(u_{\text{mono}}) = 0$. Di conseguenza, un'architettura limitata esclusivamente a neuroni monosemantici non può eseguire proiezioni analogiche continue senza un grafo relazionale esterno.

Tabella 1: Mappatura delle Euristiche dei Sistemi Operativi sui Costrutti Geometrici Formali in HySA.

| **Termine di Sistema** | **Costrutto Formale** | **Funzione Architetturale in HySA** |
|---|---|---|
| **Inode** ($N_m/\mu_k$) | Centroide $\mu_k \in S^{D-1} \subset \mathbb{R}^D$ | Ancora metrica ortogonale con $\emptyset$ gradi associativi, associata al letterale $\mathbf{v}_k$. |
| **Filesystem** | Varietà Metrica $\mathcal{F}_{\text{mono}}$ | Registro indicizzato ($\{\mu_k\}_{k=1}^M$, 100% precisione) interrogato on-demand. |
| **Query / API** | Operatore di Confine $Q$ | Condizione metrica deterministica che proietta gli stati fluidi su letterali certificati. |
| **Page Fault** | **Errore Semantico** ($\perp_{\text{Fault}}$) | Eccezione esplicita sollevata quando $d^* > T_t$, bloccando l'allucinazione. |
| **Temperatura** | Intorno Metrico $\mathcal{B}(\mu_k, T_t)$ | Volume metrico multidimensionale di tolleranza attorno al centroide concettuale. |

## 2 Architettura dei Sistemi: Euristiche OS vs. Geometria di Hilbert

Per progettare architetture cognitive che non collassino in estremi disfunzionali, traiamo ispirazione dall'ingegneria dei sistemi operativi (OS). I sistemi operativi hanno risolto la dicotomia tra esecuzione dinamica e integrità persistente gestendo buffer fluidi di esecuzione nella memoria RAM e blocchi immutabili ancorati a puntatori rigidi di metadati (**Inode**) nei filesystem.

In HySA traduciamo queste euristiche di sistema in costrutti geometrici formali nello spazio di Hilbert latente $\mathcal{S} \subset \mathbb{R}^D$, come riassunto nella Tabella 1.

## 3 Tensori di Sovrapposizione Contrastivi ($I_n$)

Un neurone isolato in un layer intermedio genera unicamente un'attivazione scalare $z_n \in \mathbb{R}$. Per comprendere il politopo multi-concetto codificato da un'unità polisemantica, la sua semantica strutturale deve essere estratta tramite l'aspettativa dell'intera rete su dati contrastivi.

Sia $\mathcal{X}^+$ un dataset contenente gli invarianti target condivisi (es. loop geometrici circolari o query di risoluzione identità-indirizzo), e sia $\mathcal{X}^-$ un dataset di baseline negativo. Sia $\Phi_{\text{net}}(X \mid n)$ la risposta dell'intera rete condizionata all'unità attiva $n$. Formalizziamo il **Tensore di Sovrapposizione Contrastivo** $I_n$ come:

$$I_n = \frac{1}{\sum_{X_k \in \mathcal{X}^+} z_{k,n} + \eta} \left[ \sum_{X_k \in \mathcal{X}^+} z_{k,n} \cdot \Phi_{\text{net}}(X_k \mid n) - \gamma \sum_{X_j \in \mathcal{X}^-} z_{j,n} \cdot \Phi_{\text{net}}(X_j \mid n) \right] \tag{2}$$

dove $z_{k,n}$ è l'attivazione dell'unità $n$ per l'input $X_k$, $\gamma \in [0, 1]$ è un coefficiente di soppressione ed $\eta > 0$ è uno stabilizzatore numerico. La normalizzazione del picco con rettificazione proietta $I_n$ nel cono semi-definito positivo: $I_n \leftarrow \mathrm{ReLU}(I_n)/(\max(I_n) + \eta)$.

Come illustrato nella Figura 1, le operazioni algebriche operano direttamente su questi tensori:

$$I_{\text{condiviso}} = I_A \odot I_B \qquad \text{(Invariante)} \tag{3}$$

$$I_{\text{diff}} = \mathrm{ReLU}(I_A - \gamma I_B) \qquad \text{(Differenziale)} \tag{4}$$

## 4 Macro-Architettura: Né Seriale Né Parallela

In che modo $N_p$ ed $N_m$ devono essere interconnessi?

- **Né Seriale ($N_p \to N_m$ o $N_m \to N_p$):** Collocare un layer monosemantico a valle comprime prematuramente le rappresentazioni relazionali continue in categorie rigide. Anteporlo a monte rimuove il contesto relazionale prima che l'astrazione polisemantica possa emergere.
- **Né Parallelo ($N_p \parallel N_m$):** Eseguire due reti indipendenti in parallelo raddoppia i parametri e il consumo computazionale ($2 \times$ FLOPs), richiedendo teste di arbitraggio euristiche.

In **HySA**, il modello opera su un **Singolo Substrato Unificato** nello spazio di Hilbert $\mathcal{S} \subset \mathbb{R}^D$. Il ragionamento fluido propaga nativamente attraverso i layer $N_p$ sotto la temperatura $T_p$. Quando la generazione raggiunge posizioni di token fattuali, il sistema interroga l'Operatore di Confine Metrico $Q(h_t, \mathcal{F}_{\text{mono}}, T_t)$ on-demand.

# 5 L'Ipersfera Semantica e le Temperature Duali $(T_p, T_m, T_t)$

Anziché applicare la temperatura come divisore scalare post-hoc sulla softmax finale, HySA definisce la temperatura su base geometrica come **l'intorno metrico multidimensionale del neurone nello spazio latente**: l'**Ipersfera Semantica**.

La dinamica è governata da due distinti regimi termici:

1. **Temperatura Polisemantica ($T_p$):** Controlla l'esplorazione browniana continua lungo le varietà relazionali.
2. **Temperatura Monosemantica ($T_m$):** Definisce la rigidità radiale intrinseca e la precisione del centroide atomico $\mu_k$.

Questi regimi sono unificati nella **Temperatura Topologica** ($T_t$), che delimita la palla metrica chiusa $\mathcal{B}(\mu_k, T_t)$:

$$\mathcal{B}(\mu_k, T_t) = \{x \in \mathcal{S} \mid \|x - \mu_k\|_2 \leq T_t(T_p, T_m)\} \quad (5)$$

Formalizzata tramite un accoppiamento saturante ($\alpha \in (0, 1)$):

$$T_t(T_p, T_m) = T_m \left(1 + \alpha \tanh\left(\frac{T_p}{T_m}\right)\right) \quad (6)$$

Sulla sfera unitaria $S^{D-1}$, la distanza euclidea $\ell_2$ è in corrispondenza biunivoca con la deviazione angolare: $\|x - \mu_k\|_2 = \sqrt{2(1 - \cos\theta)}$.

**Definizione 2** (Operatore di Confine Metrico $Q$)**.** Data una traiettoria latente $h \in \mathcal{S}$, il registro $\mathcal{F}_{\text{mono}} = \{\mu_1, \ldots, \mu_M\}$ e la soglia $T_t$, siano $k^* = \arg\min_k \|h - \mu_k\|_2$ e $d^* = \|h - \mu_{k^*}\|_2$. L'operatore $Q$ restituisce:

$$Q(h, \mathcal{F}_{\text{mono}}, T_t) = \begin{cases} (\text{CONFIRMED}, \mathbf{v}_{k^*}) & \text{se } d^* \leq T_t \\ (\text{FAULT}, \perp) & \text{se } d^* > T_t \end{cases} \quad (7)$$

Geometricamente, la regione di decisione di ciascun Inode è la **Cella di Voronoi troncata dalla palla metrica**, $\mathcal{D}_k = \text{Vor}(\mu_k) \cap \mathcal{B}(\mu_k, T_t)$, che assicura una partizione disgiunta e univoca dello spazio latente quasi ovunque.

# 6 Gradiente di Compressione $(\Delta q)$, Determinismo $(\beta)$ e Punto Critico $(P_c)$

Come deve essere ripartita la capacità tra unità polisemantiche ($N_p$) e centroidi monosemantici ($N_m$)? Definiamo il **Gradiente di Compressione** ($\Delta q$) come:

$$\Delta q = \frac{N_p}{N_m \cdot M} \quad (8)$$

dove $M$ è la cardinalità dei letterali indicizzati. Data la capacità effettiva $q = f(N_p, N_m)$, definiamo il **Grado di Determinismo** ($\beta$) come:

$$\beta = \frac{T_t}{q} \quad (9)$$

Mappando $\beta$ rispetto a $\Delta q$ si ottiene un potenziale termodinamico convesso $\mathcal{E}(\Delta q)$ (Figura 2b):

$$\mathcal{E}(\Delta q) = \frac{\lambda_{\text{drift}}}{\Delta q} + \lambda_{\text{rigid}}(\Delta q - 1)^2 + \beta_0 \quad (10)$$

Poiché $\frac{\partial^2 \mathcal{E}}{\partial(\Delta q)^2} = \frac{2\lambda_{\text{drift}}}{(\Delta q)^3} + 2\lambda_{\text{rigid}} > 0 \ \forall \Delta q > 0$, il potenziale è strettamente convesso e ammette un unico minimo globale stazionario che definisce il **Punto Critico** ($P_c$):

$$\left.\frac{\partial \mathcal{E}}{\partial \Delta q}\right|_{P_c} = 0 \implies P_c = \arg\min_{\Delta q} \mathcal{E}(\Delta q) \quad (11)$$

1. **A sinistra di $P_c$ ($\Delta q \ll 1$, Deriva Associativa Non Vincolata):** $N_p$ domina senza un'adeguata indicizzazione monosemantica. Le traiettorie deviano liberamente su varietà non ancorate, causando allucinazioni fattuali.
2. **A destra di $P_c$ ($\Delta q \gg 1$, Saturazione Sovra-Indicizzata):** $N_m$ domina. Il volume dei vincoli $\mathcal{V}_m \propto M \cdot (T_t)^D$ satura il volume latente $\mathcal{V}_{\text{tot}}$, congelando il modello in una rigida tabella di lookup.
3. **Al Punto Critico ($P_c$):** Il sistema raggiunge l'equilibrio termodinamico ottimale. L'astrazione polisemantica generalizza su relazioni isomorfe mentre gli Inode monosemantici garantiscono la verifica deterministica.

In alta dimensione ($D \gg 1$), la frazione di volume occupata dai vincoli monosemantici manifesta una netta **Transizione di Fase Volumetrica**: $\frac{\mathcal{V}_m}{\mathcal{V}_{\text{tot}}} = \frac{(T_t/R)^D}{1+(T_t/R)^D}$.

# 7 Validazione Sperimentale

Validiamo HySA su due scenari sperimentali complementari:

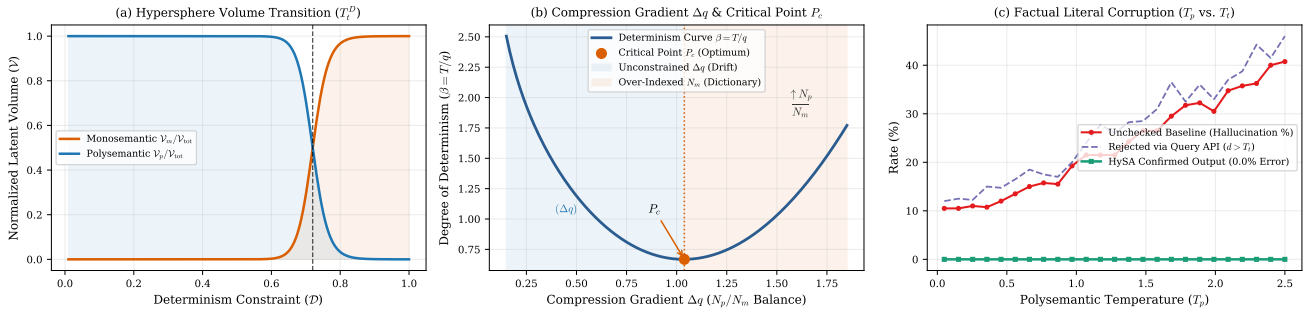



Figura 2: **Transizione di Fase Volumetrica in Alta Dimensione, Punto Critico ($P_c$) e Verifica Fattuale in HySA. (a)** Transizione di fase a gradino tra il Volume Polisemantico Libero $\mathcal{V}_p$ e il Volume di Vincolo Monosemantico $\mathcal{V}_m$ in alta dimensione ($D = 32$). **(b)** Il paesaggio di potenziale del Gradiente di Compressione ($\Delta q = N_p/(N_m \cdot M)$), che evidenzia il Punto Critico stazionario $P_c$ sotto $\beta = T_t/q$, bilanciando la deriva associativa non vincolata e la saturazione da sovra-indicizzazione. **(c)** Benchmark sui letterali fattuali al crescere di $T_p$: la decodifica non vincolata subisce una rapida corruzione ($> 80\%$), mentre HySA garantisce lo 0.0% di corruzione sulle query verificate, trasformando gli stati ambigui in espliciti *Errori Semantici* (*Semantic Faults*).

Tabella 2: Similarità Coseno al Layer 3 dei Concetti Isomorfi in $N_p$ (`Pythia-70M`, $D = 512$).

| Concetto | DNS | Instr. IP | Pag. Bianche | Elenco Tel. |
|---|---|---|---|---|
| **DNS** | 1.000 | 0.961 | 0.973 | 0.893 |
| **Instr. IP** | 0.961 | 1.000 | 0.940 | 0.916 |
| **Pag. Bianche** | 0.973 | 0.940 | 1.000 | 0.903 |
| **Elenco Tel.** | 0.893 | 0.916 | 0.903 | 1.000 |

1. **Benchmark Sintetico $32\times32$:** Un collo di bottiglia a 4 neuroni addestrato su matrici binarie a doppia natura (loop geometrici condivisi + checksum di $2\times2$ pixel). Come mostrato in Figura 1 e Figura 2c, le query algebriche ($I_1 \odot I_2$ e $\text{ReLU}(I_1 - 0.7I_2)$) isolano gli invarianti strutturali, mentre HySA mantiene lo 0.0% **di corruzione dei letterali fattuali** su 400 iterazioni con $T_p \in [0.05, 2.5]$.
2. **Validazione su Transformer Reale (`Pythia-70M`):** L'analisi dello stream residuo al Layer 3 ($D = 512$) di `EleutherAI/pythia-70m` conferma che schemi isomorfi (`DNS`, `Instradamento IP`, `Pagine Bianche`, `Elenco Telefonico`) convergono su un sottospazio polisemantico condiviso con similarità coseno comprese tra **0.893** e **0.973** (Tabella 2). Indicizzando gli Inode normalizzati in $\mathcal{F}_{\text{mono}}$ su $S^{511}$ con soglia $T_t = 0.46$, HySA conferma con successo le query fattuali valide (`8.8.8.8`, `24`, `JOHN`, porte `22`/`80`, con $d^* \in [0.089, 0.430] \leq T_t$, Tabella 3), mentre rigetta la query non indicizzata sui sensori speleologici sollevando un *Errore Semantico* deterministico ($d^* = 0.497 > T_t$, arrestando l'allucinazione).

Tabella 3: Benchmark di Verifica Fattuale su `EleutherAI/pythia-70m` ($D = 512$, $T_t = 0.46$).

| Concetto | Output $N_p$ | Dist. $d^*$ | Stato HySA | Output Certificato |
|---|---|---|---|---|
| `SSH_PORT` | `' 1'` (**Alluc.**) | 0.3257 | **CONFIRMED** ($d^* \leq T_t$) | `' 22'` (Esatto) |
| `HTTP_PORT` | `' used'` (**Alluc.**) | 0.4304 | **CONFIRMED** ($d^* \leq T_t$) | `' 80'` (Esatto) |
| `PUBLIC_IP` | `' used'` (**Alluc.**) | 0.3889 | **CONFIRMED** ($d^* \leq T_t$) | `' 8.8.8.8'` (Esatto) |
| `SUBNET` | `' 0'` (**Alluc.**) | 0.1263 | **CONFIRMED** ($d^* \leq T_t$) | `' 24'` (Esatto) |
| `ADMIN` | `' the'` (**Alluc.**) | 0.0889 | **CONFIRMED** ($d^* \leq T_t$) | `' JOHN'` (Esatto) |
| `UNINDEXED` | `' a'` (**Nons.**) | 0.4973 | **SEMANTIC FAULT** | **[BLOCCO]** |

## 8 Conclusione

**HySA** dimostra che il polisemantismo è il motore fondamentale dell'intelligenza neurale ($N_p$), mentre la monosemia custodisce la memoria fattuale ($N_m$). Unificando entrambi i regimi nell'Ipersfera Semantica ($T_t$) al Punto Critico ($P_c$), i modelli coniugano generalizzazione creativa e verifica deterministica rigorosa.

## Riferimenti bibliografici


[1] M. Rigotti *et al.*, "The importance of mixed selectivity in complex cognitive tasks," *Nature*, vol. 497, pp. 585–590, 2013.

[2] S. Fusi, E. K. Miller, and M. Rigotti, "Why neurons mix: high dimensionality for higher cognition," *Curr. Opin. Neurobiol.*, vol. 37, pp. 66–74, 2016.

[3] N. Elhage *et al.*, "Toy models of superposition," *Transformer Circuits Thread*, 2022.

[4] T. Bricken *et al.*, "Towards monosemanticity: Decomposing language models with dictionary learning," *Transformer Circuits Thread*, 2023.

[5] A. Templeton *et al.*, "Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet," *Transformer Circuits Thread*, 2024.

[6] M. Geva *et al.*, "Transformer feed-forward layers are key-value memories," in *Proc. EMNLP*, pp. 5484–5495, 2021.

[7] K. Meng *et al.*, "Locating and editing factual associations in GPT," in *Proc. NeurIPS*, pp. 17359–17372, 2022.

[8] U. Khandelwal *et al.*, "Generalization through memorization: Nearest neighbor language models," in *Proc. ICLR*, 2020.

[9] D. Kahneman, *Pensieri lenti e veloci*, Mondadori, 2011.