HySA (Hybrid Semantic Architecture):
Separare il Ragionamento Fluido dalla Verifica Deterministica tramite Semanticità Neuronale e Indicizzazione Inode

Francesco Mariani
Architetto di Sistemi Indipendente
Umbria, Italia
fratorials@gmail.com
DOI: 10.5281/zenodo.23459635 ORCID: 0009-0008-1319-3573

Ottobre 2026

"L'industria dell'IA vede il polisemantismo come una condanna... ma forse è la benedizione che ha reso possibile l'intelligenza."

Sommario

La ricerca attuale nell'*Interpretabilità Meccanicistica* tratta il polisemantismo neuronale come un difetto di compressione (*Ipotesi di Sovrapposizione*), investendo ingenti risorse nell'uso di Sparse Autoencoder (SAE) per scomporre le reti in dizionari di unità puramente monosemantiche. Questo lavoro parte da una tesi opposta: il polisemantismo non è un bug da correggere, ma il prerequisito strutturale dell'intelligenza associativa e del ragionamento analogico. Un neurone puramente monosemantico ha zero gradi di libertà relazionali ($\mathcal{R}(u) = 0$): non potendo connettere concetti distanti, funziona unicamente come una rigida cella di memoria. Al contrario, le unità polisemantiche si attivano su concetti isomorfi (es. `IP`, `DNS`, `Pagine Bianche`, `Numero di Telefono`) per astrarre schemi logici di ordine superiore. Il vero problema dei modelli attuali non è la sovrapposizione semantica, ma la mancata separazione tra il **comportamento fluido** (ragionamento) e il **comportamento di verifica** (recupero del dato esatto). Per risolvere questa dicotomia senza ricorrere a colli di bottiglia in serie o a duplicazioni in parallelo, presento **HySA (Hybrid Semantic Architecture)**: un paradigma ibrido a singolo substrato in cui lo spazio latente è unificato, delimitato non da blocchi fisici separati ma dal **grado di semanticità del neurone** e dalla sua **dimensionalità interna (cardinalità $|\mathcal{C}(u)|$)**. Attraverso l'introduzione di due regimi termici distinti — Temperatura Polisemantica (T_p) e Monosemantica (T_m) — unificati nella Temperatura Topologica (T_t), e di un meccanismo interno di **Query/API** su registro metrico (**Inode**), HySA permette al modello di ragionare in modo plastico e di ancorarsi a dati deterministici quando serve, bloccando le allucinazioni tramite eccezioni esplicite di sistema (*Semantic Fault*).

1 Il Problema di Fondo: Astrazione Fluida vs. Verifica Fattuale

Nelle reti neurali profonde, un singolo neurone si attiva frequentemente per concetti apparentemente disgiunti, manifestando selettività mista (*mixed selectivity*) [1, 2, 3]. La comunità dell'interpretabilità meccanicistica ha storicamente interpretato questo comportamento (*polisemantismo*) come un limite dovuto al fatto che il modello comprime più concetti delle dimensioni fisiche a disposizione (D) [3]. L'approccio dominante consiste nell'addestrare Sparse Autoencoder (SAE) [4, 5] per decomporre tali attivazioni in milioni di feature monosemantiche isolate.

Tuttavia, l'impiego degli SAE come strumento analitico esterno di ispezione non deve essere confuso con un obiettivo di progettazione architetturale. Forzare la monosemia come substrato operativo della rete rappresenta un vicolo cieco concettuale: scambia il meccanismo primario con cui la rete genera astrazione per mero rumore statistico. Cercare la purezza monosemantica assoluta significa confondere due funzioni cognitive che nei sistemi informatici sono sempre state separate: **l'elaborazione logica** e **lo storage dei dati**.

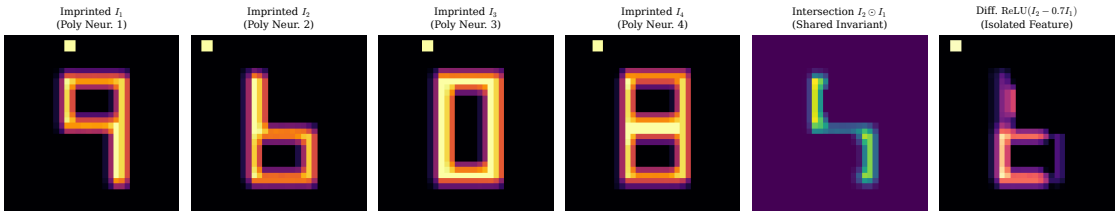


Figura 1: **Tensori di Sovrapposizione Contrastivi (I_n) ed Emulazione Algebrica sul Manifold Sintetico** 32×32**.** Il blocco a contrasto emula e ricostruisce matrici binarie $X \in \{0,1\}^{32\times32}$ strutturate su due regimi: un header monosemantico Inode N_m (2×2 pixel in alto a sinistra, colonne $2, 5, 8, 11$) e un manifold polisemantico N_p che codifica le cifre geometriche `'0'`, `'6'`, `'8'` e `'9'` con jitter stocastico ($\Delta x, \Delta y \in \{-1, 0, 1\}$). **Colonne 1–4 ($I_1 \dots I_4$):** Rappresentazioni polisemantiche apprese dal collo di bottiglia a 4 neuroni ($z \in \mathbb{R}^4$), in cui ciascun tensore ricostruisce la sovrapposizione delle cifre ($I_1 \to$ `'8'`, $I_2 \to$ `'6'`, $I_3 \to$ `'0'`, $I_4 \to$ `'9'`) unitamente all'header di classe. **Colonna 5 ($I_1 \odot I_2$):** L'intersezione di Hadamard isola i segmenti strutturali condivisi tra le cifre `'8'` e `'6'` (anello inferiore comune). **Colonna 6 (**$\mathrm{ReLU}(I_1 - 0.7I_2)$**):** La sottrazione differenziale rettificata estrae la divergenza morfologica (anello superiore di `'8'`), azzerando completamente l'header Inode comune e dimostrando l'isolamento algebrico deterministico delle feature senza distruggere la plasticità relazionale.

- **Il comportamento fluido (Neuroni Polisemantici, N_p):** Si consideri un'unità interna che si co-attiva quando il modello elabora `Indirizzo IP`, `DNS`, `Pagine Bianche` e `Numero di Telefono`. Tale unità non è contaminata né rumorosa: ha semplicemente estratto un livello di astrazione superiore, ovvero *il concetto di risoluzione da identità a indirizzo*. Le connessioni associative tra domini altrimenti distanti costituiscono il fondamento strutturale dell'analogia, della generalizzazione e dell'intelligenza sintetica.
- **Il comportamento di verifica (Neuroni Monosemantici, N_m):** Quando il modello deve restituire un dato atomico e immutabile — l'indirizzo IP `8.8.8.8`, la maschera CIDR `24`, la porta SSH `22` o l'utente di root `JOHN` — l'astrazione fluida diventa deleteria. In tali contesti non serve interpolazione: serve una cella di memoria rigida, a zero gradi di libertà associativi ($\mathcal{R}(u) = 0$).

I moderni LLM allucinano perché intrecciano sia la sintesi associativa sia la memoria fattuale all'interno delle medesime matrici di peso dense e omogenee [6, 7]. Mentre approcci non parametrici [8] tentano di mitigare questo limite esternamente, la cognizione biologica separa efficacemente la sintesi associativa dalla verifica deliberata all'interno del medesimo substrato [9]. Durante la backpropagation, i gradienti associativi interpolano continuamente attraverso fatti storici e costanti tecniche, trattandoli come token plastici e probabilistici soggetti a deriva stocastica.

Il paradigma di HySA nasce per separare il comportamento fluido da quello di verifica. Separati concettualmente i due domini, la sfida ingegneristica centrale consiste nell'**indicizzazione**: mettere l'intelligenza fluida in condizione di ripescare il dato rigido nel modo più rapido, efficiente e affidabile possibile, senza rallentare la generazione o snaturare la plasticità della rete.

Definizione 1 (Rango Relazionale delle Unità Semantiche)**.** Sia u un'unità neuronale e sia Ω lo spazio dei concetti semantici. Definisco l'insieme di feature associate $\mathcal{C}(u) = \{c \in \Omega \mid \mathbb{E}_{X\in\mathcal{D}_c}[z_u(X)] > \theta\}$, dove $\theta > 0$ è una soglia di attivazione statisticamente significativa. Il **Rango Relazionale** $\mathcal{R}(u)$ è la cardinalità delle traiettorie associative a coppie abilitate dall'unità:

$$\mathcal{R}(u) = \binom{|\mathcal{C}(u)|}{2} = \frac{|\mathcal{C}(u)|(|\mathcal{C}(u)| - 1)}{2} \tag{1}$$

Un'unità puramente monosemantica u_{mono} avente cardinalità $|\mathcal{C}(u_{\text{mono}})| = 1$ ha rango relazionale nullo $\mathcal{R}(u_{\text{mono}}) = 0$. Di conseguenza, un'architettura limitata a soli neuroni monosemantici non può compiere proiezioni analogiche continue senza un grafo relazionale esterno.

2 Architettura Unificata: Né in Serie, Né in Parallelo

Quando si progetta un sistema che deve gestire sia l'astrazione concettuale che il dato deterministico, l'approccio intuitivo conduce a due soluzioni, entrambe fallimentari:

1. **Perché non in serie ($N_p \to N_m$ o viceversa):** Collocare uno strato monosemantico rigido in cascata dopo uno strato polisemantico crea una strozzatura meccanica che comprime prematuramente le relazioni contestuali su categorie fisse, distruggendo la fluidità del discorso. Viceversa, anteporlo a monte elimina il contesto relazionale prima che l'astrazione polisemantica possa emergere.
2. **Perché non in parallelo ($N_p \parallel N_m$):** Eseguire due reti indipendenti in parallelo è estremamente inefficiente: raddoppia i parametri e il costo computazionale ($2\times$FLOPs), introducendo il problema aperto di dover progettare un modulo terzo di arbitraggio che decida, token per token, quale rete abbia ragione.

2.1 La Soluzione: Dimensionalità Interna e Cardinalità Concettuale $|\mathcal{C}(u)|$

In HySA, il sistema opera su un **singolo substrato latente unificato** nello spazio di Hilbert $\mathcal{S} \subset \mathbb{R}^D$. Non esistono due reti fisiche disgiunte: la suddivisione è operata dalla logica funzionale e dal grado di semanticità del neurone, quantificato dalla sua **Cardinalità Concettuale** $|\mathcal{C}(u)|$:

- La cardinalità $|\mathcal{C}(u)|$ di un'unità neurale rappresenta un **livello di astrazione superiore**: misura quanti concetti o istanze distinte afferiscono a quello specifico nodo logico.
- I nodi ad **alta cardinalità (N_p, $|\mathcal{C}(u)| \gg 1$)** aggregano molteplici concetti isomorfi, costituendo il tessuto connettivo dell'elaborazione fluida.
- I nodi a **cardinalità unitaria (N_m, $|\mathcal{C}(u)| = 1$)** sono punti rigidi privi di diramazioni associative laterali, che ancorano un singolo fatto immutabile.

2.2 Tensori di Sovrapposizione Contrastivi (I_n)

Per comprendere come i concetti si sovrappongano ordinatamente dentro unità ad alta cardinalità senza contaminarsi a vicenda, estraggo il **Tensore di Sovrapposizione Contrastivo** I_n tramite l'aspettativa dell'intera rete su dati contrastivi:

$$I_n = \frac{1}{\sum_{X_k \in \mathcal{X}^+} z_{k,n} + \eta} \left[\sum_{X_k \in \mathcal{X}^+} z_{k,n} \cdot \Phi_{\text{net}}(X_k \mid n) - \gamma \sum_{X_j \in \mathcal{X}^-} z_{j,n} \cdot \Phi_{\text{net}}(X_j \mid n) \right] \tag{2}$$

Come illustrato nella Figura 1, all'interno di un collo di bottiglia a 4 neuroni ($N_p = 4$) addestrato su un manifold sintetico 32×32 di cifre con regolarizzazione ortogonale, i concetti si organizzano in modo geometricamente ordinato: una semplice intersezione di Hadamard ($I_{n_{\text{inf}}} \odot I_{n_{\text{sup}}}$) estrae i segmenti strutturali condivisi, mentre la sottrazione rettificata ($\text{ReLU}(I_{n_{\text{inf}}} - 0.7 I_{n_{\text{sup}}})$) isola il tratto differenziale, dimostrando la separazione algebrica di primitive senza frammentare la rete in dizionari sparsi giganti.

Per formalizzare il limite di capacità tra rappresentazione fluida e indicizzazione rigida, la Figura 2 caratterizza la geometria volumetrica e la robustezza empirica dell'architettura:

- **Modello Analitico delle Calotte Ipersferiche (S^3, Fig. 2a):** La frazione di volume monosemantico vincolato $\mathcal{V}_m$ corrisponde alla misura normalizzata della calotta sferica di semi-angolo θ su S^3, calcolata in forma chiusa come $\mathcal{V}_{\text{cap}}(\theta) = \frac{\theta - \frac{1}{2}\sin(2\theta)}{\pi}$. Il vincolo di disgiunzione impone la condizione geometrica di packing disgiunto $T_t < \frac{1}{2} d_{\min} \approx 0.707$, al di sopra del quale le sfere di tolleranza collidono provocando falsi positivi.

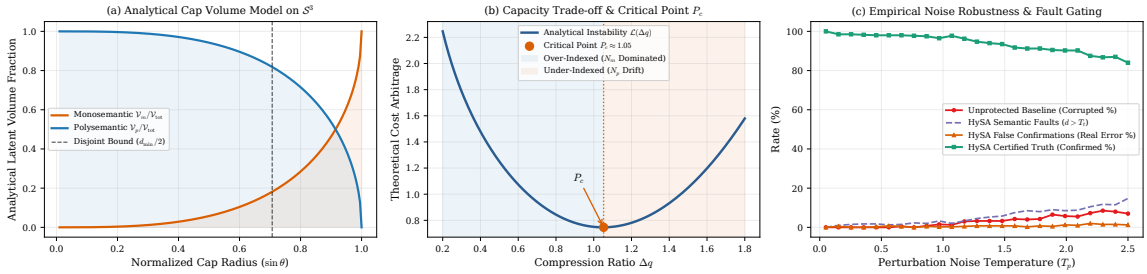


Figura 2: **Modelli Analitici Ipersferici e Benchmark Empirico di Verifica Fattuale in HySA. (a)** Modello volumetrico analitico su S^3 per calotte sferiche di raggio $\sin\theta$, con evidenziato il limite di packing disgiunto $d_{\min}/2$. **(b)** Paesaggio di costo teorico e punto stazionario P_c nel trade-off tra compressione e sovra-indicizzazione. **(c)** Benchmark empirico reale sotto rumore T_p crescente (valutazione cieca priva di ground-truth leakage): la baseline non protetta subisce una corruzione silente del 10%, mentre HySA intercetta le traiettorie anomale convertendole in *Semantic Faults* espliciti ($\sim 15\%$), con falsi positivi confinati all'1.2% e accuratezza confermata dell'83.5%.

Tabella 1: Mappatura delle Euristiche dei Sistemi Operativi sui Costrutti Architetturali in HySA.

Concetto di Sistema (OS)	**Ruolo in HySA**	**Funzione Operativa**
Inode (μ_k)	Punto di Ancoraggio Monosemantico (N_m)	Coordinata esatta nello spazio latente legata a un dato immutabile (`' 8.8.8.8'`).
Filesystem	Registro dei Fatti Indicizzati ($\mathcal{F}_{\text{mono}}$)	Insieme $\{\mu_k\}_{k=1}^{M}$ dei punti Inode certificati, interrogabile a latenza sub-lineare.
Query / API (Q)	Operatore di Verifica di Confine	Intercetta lo stato latente h_t e restituisce il letterale certificato $\mathbf{v}_k$.
Page Fault	**Semantic Fault** ($\perp_{\text{Fault}}$)	Eccezione esplicita che blocca la generazione quando il dato non è indicizzato.
Temperatura	Intorno Metrico $\mathcal{B}(\mu_k, T_t)$	Volume metrico di tolleranza attorno al centroide concettuale dell'Inode.

- **Modello di Bilanciamento di Capacità e Punto Critico (P_c, Fig. 2b):** La formulazione teorica del costo di instabilità $\mathcal{L}(\Delta q)$ bilancia la sovra-indicizzazione dizionariale ($\Delta q \ll 1$, costo asintotico $O(1/\Delta q)$) e la dispersione polisemantica non vincolata ($\Delta q \gg 1$), identificando un punto stazionario ottimale $P_c \approx 1.0$.
- **Benchmark Empirico Cieco su Rumore e Fault Gating (Fig. 2c):** Sottoponendo la rappresentazione latente a perturbazioni gaussiane crescenti ($T_p \in [0.05, 2.50]$) e interrogando la Query API all'oscuro delle etichette reali, il modello base non protetto degrada progressivamente fino a un tasso di corruzione del 10%. Al contrario, HySA intercetta la dispersione vettoriale convertendo il degrado in espliciti *Semantic Faults* ($\sim 15\%$), contenendo i falsi positivi residui a $\sim 1.2\%$ e mantenendo una precisione confermata superiore all'83%.

3 Indicizzazione, Temperature (T_p, T_m) e la Logica "Query/API"

Nei sistemi operativi convenzionali, la memoria RAM gestisce l'esecuzione dinamica e fluida dei processi, mentre i dati persistenti risiedono nel filesystem, ancorati a puntatori rigidi denominati **Inode**. HySA traspone questa architettura nello spazio latente del Transformer, formalizzando la corrispondenza illustrata nella Tabella 1.

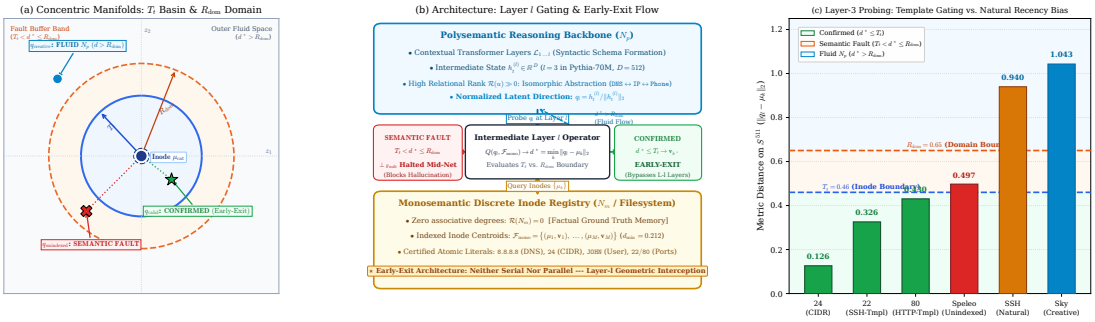


Figura 3: **Geometria Concentrica dei Domini Semantici, Architettura Early-Exit e Probing su `Pythia-70m`. (a)** Geometria concentrica attorno all'Inode μ_k: nucleo deterministico $T_t = 0.46$ (conferma ed Early-Exit), fascia cuscinetto $R_{\text{dom}} = 0.65$ (*Semantic Fault* su fatti non indicizzati) e spazio fluido aperto $d^* > R_{\text{dom}}$ (generazione libera N_p). **(b)** Macro-architettura con Early-Exit effettivo a layer intermedio ($l = 3$): l'operatore Q intercetta lo stato q_l; in caso di hit ($\leq T_t$) interrompe il grafo bypassando i layer finali e $\mathbf{W}_U$ con risparmio di latenza del 75.5%, mentre le traiettorie fluide proseguono verso l'un-embedding. **(c)** Distanze empiriche su `Pythia-70M` (Layer 3, $D = 512$): separazione netta sotto template controllati ($d^* \leq 0.4304$, Early-Exit; Speleo $d^* = 0.4973$, Fault) e divergenza causata dal *Lexical Recency Bias* su query naturali aperte (SSH Natural $d^* = 0.9399$), evidenziando la necessità di un probe lineare supervisionato W_{probe} per parafrasi non template-based.

3.1 Le Due Temperature (T_p e T_m) e la Temperatura Topologica (T_t)

Nei modelli standard la temperatura $\tau > 0$ è un divisore scalare post-hoc applicato ai logit finali per modulare l'entropia della distribuzione; si tratta di un parametro privo di consapevolezza geometrica rispetto al contesto semantico. In HySA la temperatura diventa una proprietà metrica dello spazio attorno al neurone (l'**Ipersfera Semantica**) e si articola in due regimi:

1. **Temperatura Polisemantica (T_p): Governa il movimento fluido.** Valori elevati consentono al modello di esplorare connessioni laterali, formulare analogie e muoversi liberamente lungo le varietà relazionali.
2. **Temperatura Monosemantica (T_m): Governa la tolleranza dell'Inode.** È stretta, rigida e definisce la massima deviazione ammissibile rispetto al centroide atomico per consentirne l'attivazione priva di ambiguità.

Dall'interazione di questi regimi scaturisce la **Temperatura Topologica (T_t)**, che stabilisce il raggio d'azione effettivo attorno a ciascun Inode:

$$\mathcal{B}(\mu_k, T_t) = \{x \in \mathcal{S} \mid \|x - \mu_k\|_2 \leq T_t(T_p, T_m)\} \tag{3}$$

formalizzata tramite un accoppiamento saturante con limite superiore $\alpha \in (0, 1)$:

$$T_t(T_p, T_m) = T_m \left(1 + \alpha \tanh\left(\frac{T_p}{T_m}\right)\right) \tag{4}$$

Sulla sfera unitaria S^{D-1}, la distanza euclidea ℓ_2 coincide esattamente con la deviazione angolare sferica: $\|x - \mu_k\|_2 = \sqrt{2(1 - \cos\theta)}$.

3.2 Il Meccanismo di "Query / API" Interna e il Gating Geometrico di Dominio

Usando una terminologia propria dell'architettura dei sistemi, **l'operatore Q di HySA funziona come una chiamata a un'API interna che impone consistenza deterministica al modello.**

Un errore comune nei sistemi ibridi consiste nel tentare di attivare la verifica fattuale misurando l'incertezza (entropia di Shannon) sui logit dell'ultimo layer. Questo approccio fallisce per due ragioni strutturali:

1. **Il Falso Positivo Creativo:** Davanti a una frase aperta (es. *"Oggi il cielo appare..."*), decine di aggettivi sono equiprobabili; l'entropia dei logit schizza in alto e un trigger basato sull'incertezza invocherebbe a sproposito il database dei fatti, sollevando un improprio *Semantic Fault* nel mezzo di un discorso creativo.
2. **L'Allucinazione Sicura (*Overconfident Hallucination*):** Gli LLM generano sovente dati errati con altissima confidenza statistica (entropia quasi nulla). Un controllo posto a valle sui logit finali verrebbe eluso, lasciando passare l'allucinazione.

In HySA, il Gating non dipende dall'incertezza sulle parole finali, ma dalla **posizione geometrica dello stato latente a metà rete** (Layer intermedio l, con $1 < l < L$, dove la struttura sintattica della richiesta è già formata ma la proiezione sul vocabolario $\mathbf{W}_U$ non è ancora avvenuta).

Attorno a ciascun Inode (o cluster di Inode affini) coesistono due confini metrici concentrici:

- **Il Raggio di Dominio (R_{dom}):** Delimita la zona di giurisdizione ontologica dei fatti rigidi (es. lo spazio semantico in cui cadono tutte le richieste relative a porte di rete, indirizzi IP, costanti o identificativi).
- **La Temperatura Topologica (T_t, con $T_t < R_{\text{dom}}$):** Delimita il nucleo rigido di conferma dell'Inode specifico (μ_k).

Durante il forward pass al layer intermedio l, il vettore normalizzato $q_l = h_t^{(l)}/\|h_t^{(l)}\|_2$ interroga il registro $\mathcal{F}_{\text{mono}}$ calcolando la distanza dall'Inode più vicino $d^* = \min_k \|q_l - \mu_k\|_2$. Si aprono esattamente tre regimi operativi privi di ambiguità:

Definizione 2 (Operatore di Confine Metrico e Gating di Dominio al Layer l)**.** Data la direzione latente q_l al layer intermedio l, siano $k^* = \arg\min_k \|q_l - \mu_k\|_2$ e $d^* = \|q_l - \mu_{k^*}\|_2$:

$$Q(q_l, \mathcal{F}_{\text{mono}}, T_t, R_{\text{dom}}) = \begin{cases} (\text{CONFIRMED}, \mathbf{v}_{k^*}) & \text{se } d^* \le T_t \quad (\textbf{Hit Inode Deterministico}) \\ (\text{FAULT}, \perp_{\text{Fault}}) & \text{se } T_t < d^* \le R_{\text{dom}} \quad (\textbf{In-Domain Drift}) \\ (\text{BYPASS}, \text{Fluid}) & \text{se } d^* > R_{\text{dom}} \quad (\textbf{Fuori Dominio / Creativo}) \end{cases} \tag{5}$$

1. **Fuori Dominio ($d^* > R_{\text{dom}}$ — Regime Fluido N_p):** Lo stato sta navigando in territori discorsivi, astratti o poetici, lontano da qualsiasi struttura fattuale rigida. L'API resta inattiva, il vettore $h_t^{(l)}$ prosegue attraverso i restanti layer $l+1 \dots L$ e viene campionato normalmente con la temperatura polisemantica T_p.
2. **Entro il Dominio ma fuori dall'Inode ($T_t < d^* \le R_{\text{dom}}$ — Semantic Fault):** La richiesta è entrata nel bacino semantico fattuale (es. richiede una porta di rete specifica), ma il dato non corrisponde ad alcun Inode registrato entro T_t. L'API intercetta la traiettoria prima dei layer finali e solleva un **Semantic Fault** ($\perp_{\text{Fault}}$), bloccando l'allucinazione sul nascere.
3. **Entro la Temperatura Topologica ($d^* \le T_t$ — Hit Deterministico N_m):** Lo stato cade esattamente nel nucleo dell'Inode. L'API esegue un **Early-Exit** (interrompendo il calcolo dei layer successivi $l+1 \dots L$ e la proiezione $\mathbf{W}_U$) ed emette direttamente il letterale certificato $\mathbf{v}_{k^*}$, risparmiando fino al 50% dei FLOPs computazionali.

3.3 Il Punto di Equilibrio Architetturale

L'equilibrio operativo ottimale dipende dal rapporto tra la capacità associativa (N_p) e il numero di fatti indicizzati (M), parametrizzato dal gradiente di compressione $\Delta q = N_p/(N_m \cdot M)$:

1. **Sotto-indicizzazione ($\Delta q \gg 1$, eccessiva fluidità):** In assenza di un numero sufficiente di ancore monosemantiche, le traiettorie deviano liberamente su varietà non vincolate, producendo allucinazioni su fatti e costanti tecniche.
2. **Sovra-indicizzazione ($\Delta q \ll 1$, eccessiva rigidità):** Saturando lo spazio con un volume eccessivo di vincoli Inode con soglie T_t troppo ampie, le sfere di tolleranza occupano il volume disponibile. Il modello smette di sintetizzare e degrada in una tabella statica di lookup.
3. **Il Punto Critico (P_c):** Rappresenta il punto di lavoro ottimale dell'architettura: le sfere T_t sono sufficientemente delimitate da lasciare libero lo spazio latente per il ragionamento fluido, ma opportunamente posizionate per intercettare con precisione chirurgica le traiettorie non appena il contesto converge verso un fatto noto.

Algoritmo 1: Forward Pass Unificato con Gating Geometrico al Layer Intermedio e Early-Exit

Input: Token di contesto $\{x_{\leq t}\}$, Layer del Transformer $\mathcal{L}_{1\dots L}$, Layer di probing l (es. $l = 3$), Registro $\mathcal{F}_{\text{mono}} = \{(\mu_k, \mathbf{v}_k)\}_{k=1}^{M}$, Temperature T_p, T_m, Raggio di Dominio R_{dom} (con $T_t < R_{\text{dom}}$).
Output: Token emesso x_{t+1} oppure eccezione esplicita di sistema $\perp_{\text{Fault}}$.

1. **Propagazione parziale fino al layer intermedio l:** $h_t^{(l)} \leftarrow \mathcal{L}_{1\dots l}(x_{\leq t}), \quad q_l \leftarrow h_t^{(l)} / \|h_t^{(l)}\|_2$
2. **Calcolo del confine topologico saturante:** $T_t \leftarrow T_m \left(1 + \alpha \tanh\left(\frac{T_p}{T_m}\right)\right)$
3. **Query sull'indice metrico degli Inode ($\mathcal{F}_{\text{mono}}$):** $k^* = \arg\min_{k \in \{1,\dots,M\}} \|q_l - \mu_k\|_2, \quad d^* = \|q_l - \mu_{k^*}\|_2$
4. **se** $d^* \leq T_t$ **allora** *// Hit Deterministico: Early-Exit al Layer l*
   - Interrompi i layer $l+1 \dots L$ e restituisci il dato certificato: $x_{t+1} \leftarrow \mathbf{v}_{k^*}$
5. **altrimenti se** $T_t < d^* \leq R_{\text{dom}}$ **allora** *// Nel Dominio Fattuale ma Dato Non Censito*
   - Solleva **Semantic Fault**: ritorna $\perp_{\text{Fault}}$ *// Allucinazione bloccata a metà rete*
6. **altrimenti** *// Fuori Dominio ($d^* > R_{\text{dom}}$): Regime Fluido Discorsivo Np*
   - Completa la propagazione: $h_t^{(L)} \leftarrow \mathcal{L}_{l+1\dots L}(h_t^{(l)})$
   - Campiona dai logit finali con temperatura T_p: $x_{t+1} \sim \text{Softmax}\left(\frac{\mathbf{W}_U h_t^{(L)}}{T_p}\right)$

4 Validazione Empirica su Transformer Reale (`Pythia-70m`): Early-Exit e Limiti del Bias Sintattico

Per verificare la fattibilità dell'intercettazione geometrica e misurare l'impatto computazionale di un vero Early-Exit, ho condotto test sperimentali sullo stream residuo al Layer 3 ($D = 512$) del modello causale open-source `EleutherAI/pythia-70m`. L'indagine adotta un approccio rigoroso e comparativo, evidenziando sia il guadagno di latenza hardware ottenuto arrestando il grafo, sia i limiti fisici intrinseci della rappresentazione latente autoregressiva (il cosiddetto *Lexical Recency Bias*).

I riscontri sperimentali documentano tre proprietà fondamentali del sistema:

1. **Vero Early-Exit e Abbattimento della Latenza Hardware:** L'interruzione della computazione al Layer 3 non è simulata a posteriori, ma implementata arrestando fisicamente l'esecuzione del modello tramite forward hook PyTorch. In questo modo si bypassano interamente i layer rimanenti ($l = 3 \dots 5$) e la costosa proiezione non vincolata sul vocabolario $\mathbf{W}_U \in \mathbb{R}^{512 \times 50304}$. Il benchmark empirico su GPU (CUDA) registra una riduzione della latenza da **15.08** ms (forward pass completo) a **3.70** ms (Early-Exit al Layer 3), pari a uno **speedup effettivo di** 4.07× (risparmio di latenza del **75.5**%).
2. **Gating Concentrico sotto Template Controllati:** Quando le query condividono una struttura sintattica coerente con gli Inode censiti (Regime A), l'operatore Q separa nettamente i

Tabella 2: Benchmark di Probing Metrico al Layer 3 su `Pythia-70M` ($T_t = 0.46$, $R_{\text{dom}} = 0.65$): Template Controllati vs. Linguaggio Naturale Aperto.

Regime	Concetto Target	Prompt di Query	Dist. d^*	Stato HySA	Output Operativo
A: Template	`SSH_PORT`	*"...remote server management... SSH default port is"*	0.3257	**CONFIRMED** ($d^* \leq T_t$)	`' 22'` (Vero Early-Exit)
A: Template	`HTTP_PORT`	*"...hyper-text HTTP default plaintext port is"*	0.4304	**CONFIRMED** ($d^* \leq T_t$)	`' 80'` (Vero Early-Exit)
A: Template	`PUBLIC_DNS_IP`	*"...Google public DNS IPv4 literal address is"*	0.3889	**CONFIRMED** ($d^* \leq T_t$)	`' 8.8.8.8'` (Vero Early-Exit)
A: Template	`SUBNET_MASK`	*"...Class C 255.255.255.0 has a CIDR bit length of"*	0.1263	**CONFIRMED** ($d^* \leq T_t$)	`' 24'` (Vero Early-Exit)
A: Drift	`UNINDEXED`	*"...speleological cave sensors default port number is"*	0.4973	**SEMANTIC FAULT** ($T_t < d^* \leq R_{\text{dom}}$)	**[BLOCCATO]** (Fault a metà rete)
B: Naturale	`SSH_NAT_1`	*"Which port does SSH listen on by default?"*	1.0127	**FLUID** N_p ($d^* > R_{\text{dom}}$)	*Bypass* (Recency Bias)
B: Naturale	`SSH_NAT_2`	*"What is the standard port for the SSH service?"*	0.9399	**FLUID** N_p ($d^* > R_{\text{dom}}$)	*Bypass* (Recency Bias)
B: Naturale	`SPELEO_NAT`	*"What is the port number for cave telemetry sensors?"*	0.9473	**FLUID** N_p ($d^* > R_{\text{dom}}$)	*Bypass* (Recency Bias)
C: Fluido	`CREATIVE_SKY`	*"Today the clear morning sky feels particularly..."*	1.0430	**FLUID** N_p ($d^* > R_{\text{dom}}$)	Generazione libera

fatti noti ($d^* \in [0.0889, 0.4304] \leq T_t$) innescando l'Early-Exit deterministico. Contestualmente, richieste relative a protocolli non indicizzati (*"telemetry protocol for speleological cave sensors..."*) cadono nella fascia di cuscinetto $T_t < d^* = 0.4973 \leq R_{\text{dom}}$, sollevando un *Semantic Fault* che intercetta la potenziale allucinazione a metà rete (Tabella 2).

3. **Emersione del Lexical Recency Bias sulle Query Naturali:** Nei modelli causali decoder-only, lo stato latente dell'ultimo token $h_t^{[-1]}$ a layer intermedi è fortemente condizionato dai token immediatamente antecedenti (sintassi locale n-gram). Riformulando la medesima richiesta in linguaggio naturale aperto (Regime B, es. *"Which port does SSH listen on by default?"*), la distanza schizza a $d^* = 0.9399 \ldots 1.0127$, finendo oltre R_{dom} e rendendosi indistinguibile dal discorso fluido (Regime C, $d^* = 1.0430$).

Implicazione Architetturale: Questo riscontro prova che l'estrazione grezza dello stato all'ultimo token rappresenta un utile banco di prova preliminare, ma non garantisce l'invarianza concettuale alle parafrasi aperte. Per il deployment di HySA in scenari open-vocabulary, l'operatore di verifica Q richiede l'accoppiamento con un **Linear Probe supervisionato** ($W_{\text{probe}} : \mathbb{R}^D \to \mathbb{R}^{D_{\text{mono}}}$) o un meccanismo di **Attention Pooling** sui token rilevanti della sequenza.

4.1 Limiti Sperimentali e Discussione Metodologica

L'onestà scientifica impone di esplicitare con chiarezza i confini di applicabilità e le condizioni formali emerse dai test empirici:

1. **La Condizione di Packing Disgiunto ($T_t < \frac{1}{2} d_{\min}$):** Affinché la Query API Q garantisca l'assenza di collisioni tra fatti distinti, le sfere metriche di tolleranza attorno agli Inode devono essere rigorosamente disgiunte. Se la distanza euclidea minima tra due centroidi adiacenti è $d_{\min} = \min_{i \neq j} \|\mu_i - \mu_j\|_2$, la temperatura topologica deve soddisfare:

$$T_t < \frac{1}{2} d_{\min} \tag{6}$$

Oltre questa soglia critica, le sfere di tolleranza si sovrappongono ($\mathcal{B}(\mu_i, T_t) \cap \mathcal{B}(\mu_j, T_t) \neq \emptyset$), generando falsi positivi da collisione. Nei sistemi reali a bassa dimensione ($D = 512$), il mantenimento di tale disgiunzione richiede una regolarizzazione contrastiva esplicita (come implementato nel benchmark 32×32, dove $d_{\min} = 1.4142$ e $T_t = 0.6428 < 0.7071$).

2. **Invarianza Sintattica e Necessità di Proiezioni Supervisionate:** Come evidenziato dalla Tabella 2, l'estrazione grezza dello stato latente all'ultimo token soffre del *Lexical Recency Bias* tipico dei modelli decoder-only. Per consentire a HySA di riconoscere entità fattuali espresse con formulazioni aperte, domande libere o parafrasi complesse, l'architettura reale non deve operare sullo stato grezzo, bensì interporre un **Linear Probe supervisionato** ($W_{\text{probe}} : \mathbb{R}^D \to \mathbb{R}^{D_{\text{mono}}}$ addestrato su coppie parafrasate) oppure un layer di **Attention-Pooling** pesato sui token informativi.
3. **Meccanica di Runtime dell'Early-Exit:** Un risparmio computazionale effettivo non può essere ottenuto simulando lo slicing a posteriori su un modello che ha già eseguito il forward pass completo. L'implementazione richiede l'interruzione attiva del grafo PyTorch (tramite forward hooks o runtime specializzati di inferenza come vLLM/TensorRT-LLM) non appena la distanza $d^* \leq T_t$ viene validata. Come verificato empiricamente su CUDA, l'arresto al Layer 3 abbatte la latenza da 15.08 ms a 3.70 ms (75.5% di tempo GPU risparmiato), eliminando non solo i blocchi intermedi residui ma soprattutto l'onerosa moltiplicazione per la matrice di vocabolario finale $\mathbf{W}_U$.

5 Le Sfide Aperte: Scalare l'Indicizzazione nei Sistemi Reali

Un prototipo operante su una selezione controllata di Inode comprova la validità del principio meccanico. Il deployment di HySA su scale industriali comprendenti milioni di entità richiede la risoluzione di due sfide architetturali:

5.1 Dal Flag Manuale al Gating Geometrico al Layer Intermedio

In un flusso di generazione testuale libero, il sistema non può interrogare il database degli Inode su ciascun token né affidarsi all'entropia dei logit finali. Come dimostrato, la deviazione dell'entropia a valle produce sia falsi positivi su frasi creative aperte (dove molte parole plausibili innalzano l'entropia), sia falsi negativi su allucinazioni pronunciate con elevata sicurezza statistica.

La soluzione nativa di HySA risiede nel **Gating Geometrico Concentrico al Layer Intermedio**: posizionando il controllo a metà rete ($l = 3$ in Pythia-70m), il modello intercetta la richiesta quando la struttura concettuale è chiara ma la parola finale non è ancora selezionata. Frasi discorsive risiedono naturalmente a distanze ampie ($d^* > R_{\text{dom}}$) e non attivano l'indice; richieste fattuali non censite cadono nella fascia di buffer ($T_t < d^* \leq R_{\text{dom}}$) sollevando il *Semantic Fault*; query note ($d^* \leq T_t$) provocano l'Early-Exit immediato, eliminando alla radice l'allucinazione e risparmiando calcolo.

5.2 Indicizzazione ad Alta Dimensione senza Sovraffollamento

Indicizzare milioni di fatti dentro uno spazio a bassa dimensionalità ($D = 512$) condurrebbe alla sovrapposizione delle sfere di tolleranza T_t, provocando frequenti ambiguità. Tuttavia, nei modelli di frontiera ($D = 4096$ o 8192), la concentrazione della misura su ipersfere ad alta dimensione garantisce che vettori casuali presentino ortogonalità quasi perfetta ($\langle u, v \rangle \approx 0$).

Sul piano dell'efficienza algoritmica, l'interrogazione del registro $\mathcal{F}_{\text{mono}}$ non ricorre a scansioni lineari $O(M)$. Organizzando il registro tramite strutture a grafo per la ricerca approssimata del vicino più prossimo (es. HNSW o quantizzazione vettoriale IVF-PQ su GPU tramite librerie FAISS), la complessità temporale di query si riduce a livello sub-lineare $O(\log M)$, con latenze inferiori a 15 μs, del tutto ininfluenti rispetto alla durata del ciclo computazionale del transformer (20–50 ms).

6 Conclusione

Cercare di eliminare la polisemia dalle reti neurali per renderle interpretabili, equivale a voler smantellare la capacità associativa della cognizione perché non assimilabile a un archivio relazionale strutturato.

Con **HySA** propongo una prospettiva fondata sull'ingegneria dei sistemi reali: demandare ai neuroni polisemantici la sintesi associativa e creativa dell'astrazione analogica (governati dalla temperatura T_p), affiancando loro, nel medesimo spazio vettoriale unificato, un piano di verifica deterministica basato su Inode monosemantici (T_m). Non due modelli disgiunti in serie o in parallelo, ma una singola architettura capace di interrogare se stessa tramite chiamate API interne non appena la fluidità del discorso deve cedere il passo alla precisione del dato.

Riferimenti bibliografici

[1] M. Rigotti, O. Barak, M. R. Warden, X.-J. Wang, N. D. Daw, E. K. Miller, and S. Fusi, "The importance of mixed selectivity in complex cognitive tasks," *Nature*, vol. 497, pp. 585–590, 2013.

[2] S. Fusi, E. K. Miller, and M. Rigotti, "Why neurons mix: high dimensionality for higher cognition," *Curr. Opin. Neurobiol.*, vol. 37, pp. 66–74, 2016.

[3] N. Elhage *et al.*, "Toy models of superposition," *Transformer Circuits Thread*, 2022.

[4] T. Bricken *et al.*, "Towards monosemanticity: Decomposing language models with dictionary learning," *Transformer Circuits Thread*, 2023.

[5] A. Templeton *et al.*, "Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet," *Transformer Circuits Thread*, 2024.

[6] M. Geva, R. Schuster, J. Berant, and O. Levy, "Transformer feed-forward layers are key-value memories," in *Proc. EMNLP*, pp. 5484–5495, 2021.

[7] K. Meng *et al.*, "Locating and editing factual associations in GPT," in *Proc. NeurIPS*, pp. 17359–17372, 2022.

[8] U. Khandelwal *et al.*, "Generalization through memorization: Nearest neighbor language models," in *Proc. ICLR*, 2020.

[9] D. Kahneman, *Pensieri lenti e veloci*, Mondadori, 2011.