# HySA (Hybrid Semantic Architecture):
## Separare il Ragionamento Fluido dalla Verifica Deterministica tramite Semanticità Neuronale e Indicizzazione Inode

**Francesco Mariani**
*Architetto di Sistemi Indipendente*
Umbria, Italia
fratorials@gmail.com
DOI: 10.5281/zenodo.23459635 ORCID: 0009-0008-1319-3573

Ottobre 2026

*"L'industria dell'IA vede il polisemantismo come una condanna... ma forse è la benedizione che ha reso possibile l'intelligenza."*

**Sommario**

La ricerca attuale nell'*Interpretabilità Meccanicistica* tratta il polisemantismo neuronale come un difetto di compressione (*Ipotesi di Sovrapposizione*), investendo ingenti risorse nell'uso di Sparse Autoencoder (SAE) per scomporre le reti in dizionari di unità puramente monosemantiche. Questo lavoro parte da una tesi opposta: il polisemantismo non è un bug da correggere, ma il prerequisito strutturale dell'intelligenza associativa e del ragionamento analogico. Un neurone puramente monosemantico ha zero gradi di libertà relazionali ($\mathcal{R}(u) = 0$): non potendo connettere concetti distanti, funziona unicamente come una rigida cella di memoria. Al contrario, le unità polisemantiche si attivano su concetti isomorfi (es. `IP`, `DNS`, `Pagine Bianche`, `Numero di Telefono`) per astrarre schemi logici di ordine superiore. Il vero problema dei modelli attuali non è la sovrapposizione semantica, ma la mancata separazione tra il **comportamento fluido** (ragionamento) e il **comportamento di verifica** (recupero del dato esatto). Per risolvere questa dicotomia senza ricorrere a colli di bottiglia in serie o a duplicazioni in parallelo, presentiamo **HySA (Hybrid Semantic Architecture)**: un paradigma ibrido a singolo substrato in cui lo spazio latente è unificato, delimitato non da blocchi fisici separati ma dal **grado di semanticità del neurone** e dalla sua **dimensionalità interna (cardinalità $M$)**. Attraverso l'introduzione di due regimi termici distinti — Temperatura Polisemantica ($T_p$) e Monosemantica ($T_m$) — unificati nella Temperatura Topologica ($T_t$), e di un meccanismo interno di **Query/API** su registro metrico (**Inode**), HySA permette al modello di ragionare in modo plastico e di ancorarsi a dati deterministici quando serve, bloccando le allucinazioni tramite eccezioni esplicite di sistema (*Semantic Fault*).

## 1 Il Problema di Fondo: Astrazione Fluida vs. Verifica Fattuale

Nelle reti neurali profonde, un singolo neurone si attiva frequentemente per concetti apparentemente disgiunti. La comunità dell'interpretabilità meccanicistica ha storicamente interpretato questo comportamento (*polisemantismo*) come un limite dovuto al fatto che il modello comprime più concetti ($M$) delle dimensioni fisiche a disposizione ($D$) [3]. L'approccio dominante consiste nell'addestrare Sparse Autoencoder (SAE) [4, 5] per decomporre tali attivazioni in milioni di feature monosemantiche isolate.

Tuttavia, l'impiego degli SAE come strumento analitico esterno di ispezione non deve essere confuso con un obiettivo di progettazione architetturale. Forzare la monosemia come substrato operativo della rete rappresenta un vicolo cieco concettuale: scambia il meccanismo primario con cui la rete genera astrazione per mero rumore statistico. Cercare la purezza monosemantica assoluta significa confondere due funzioni cognitive che nei sistemi informatici sono sempre state separate: **l'elaborazione logica** e **lo storage dei dati**.

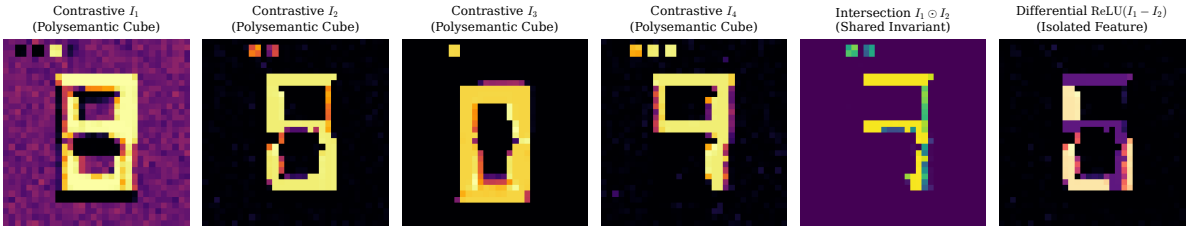



Figura 1: **Tensori di Sovrapposizione Contrastivi ($I_n$) e Query Semantiche Algebriche sul Benchmark $32 \times 32$.** Le Colonne 1–4 mostrano le rappresentazioni polisemantiche apprese da un collo di bottiglia a 4 neuroni. Ciascun tensore cattura primitive geometriche multiple. La Colonna 5 isola l'invariante strutturale condiviso tramite intersezione di Hadamard ($I_1 \odot I_2$). La Colonna 6 estrae la divergenza differenziale tramite sottrazione rettificata (ReLU$(I_1 - 0.7I_2)$), dimostrando l'isolamento algebrico delle feature senza distruggere la connettività polisemantica.

- **Il comportamento fluido (Neuroni Polisemantici, $N_p$):** Si consideri un'unità interna che si co-attiva quando il modello elabora `Indirizzo IP`, `DNS`, `Pagine Bianche` e `Numero di Telefono`. Tale unità non è contaminata né rumorosa: ha semplicemente estratto un livello di astrazione superiore, ovvero *il concetto di risoluzione da identità a indirizzo*. Le connessioni associative tra domini altrimenti distanti costituiscono il fondamento strutturale dell'analogia, della generalizzazione e dell'intelligenza sintetica.
- **Il comportamento di verifica (Neuroni Monosemantici, $N_m$):** Quando il modello deve restituire un dato atomico e immutabile — l'indirizzo IP `8.8.8.8`, la maschera CIDR `24`, la porta SSH `22` o l'utente di root `JOHN` — l'astrazione fluida diventa deleteria. In tali contesti non serve interpolazione: serve una cella di memoria rigida, a zero gradi di libertà associativi ($\mathcal{R}(u) = 0$).

I moderni LLM allucinano perché intrecciano entrambi i regimi all'interno delle medesime matrici di peso dense e omogenee [6]. Durante la backpropagation, i gradienti associativi interpolano continuamente attraverso fatti storici e costanti tecniche, trattandoli come token plastici e probabilistici soggetti a deriva stocastica.

Il paradigma di HySA nasce per separare il comportamento fluido da quello di verifica. Separati concettualmente i due domini, la sfida ingegneristica centrale consiste nell'**indicizzazione**: mettere l'intelligenza fluida in condizione di ripescare il dato rigido nel modo più rapido, efficiente e affidabile possibile, senza rallentare la generazione o snaturare la plasticità della rete.

**Definizione 1** (Rango Relazionale delle Unità Semantiche)**.** Sia $u$ un'unità neuronale e sia $\Omega$ lo spazio dei concetti semantici. Definiamo l'insieme di feature associate $\mathcal{C}(u) = \{c \in \Omega \mid \mathbb{E}_{X \in \mathcal{D}_c}[z_u(X)] > \theta\}$, dove $\theta > 0$ è una soglia di attivazione statisticamente significativa. Il **Rango Relazionale** $\mathcal{R}(u)$ è la cardinalità delle traiettorie associative a coppie abilitate dall'unità:

$$\mathcal{R}(u) = \binom{|\mathcal{C}(u)|}{2} = \frac{|\mathcal{C}(u)|(|\mathcal{C}(u)| - 1)}{2} \tag{1}$$

Un'unità puramente monosemantica $u_{\text{mono}}$ con $|\mathcal{C}(u_{\text{mono}})| = 1$ ha rango relazionale nullo: $\mathcal{R}(u_{\text{mono}}) = 0$. Di conseguenza, un'architettura limitata esclusivamente a neuroni monosemantici non può eseguire proiezioni analogiche continue senza introdurre un grafo relazionale esterno.

## 2 Architettura Unificata: Né in Serie, Né in Parallelo

Quando si progetta un sistema che deve gestire sia l'astrazione concettuale che il dato deterministico, l'approccio intuitivo conduce a due soluzioni, entrambe fallimentari:

1. **Perché non in serie ($N_p \to N_m$ o viceversa):** Collocare uno strato monosemantico rigido in cascata dopo uno strato polisemantico crea una strozzatura meccanica che comprime prematuramente le relazioni contestuali su categorie fisse, distruggendo la fluidità del discorso. Viceversa, anteporlo a monte elimina il contesto relazionale prima che l'astrazione polisemantica possa emergere.
2. **Perché non in parallelo ($N_p \parallel N_m$):** Eseguire due reti indipendenti in parallelo è estremamente inefficiente: raddoppia i parametri e il costo computazionale ($2 \times$ FLOPs), introducendo il problema aperto di dover progettare un modulo terzo di arbitraggio che decida, token per token, quale rete abbia ragione.

### 2.1 La Soluzione: Dimensionalità Interna e Cardinalità $[M]$

In HySA, il sistema opera su un **singolo substrato latente unificato** nello spazio di Hilbert $\mathcal{S} \subset \mathbb{R}^D$. Non esistono due reti fisiche disgiunte: la suddivisione è operata dalla logica funzionale e dal grado di semanticità del neurone, quantificato dalla sua **Cardinalità** $[M]$:

- La cardinalità $M$ di un'unità neurale rappresenta un **livello di astrazione superiore**: misura quanti concetti o istanze distinte afferiscono a quello specifico nodo logico.
- I nodi ad **alta cardinalità ($N_p$, $M \gg 1$)** aggregano molteplici concetti isomorfi, costituendo il tessuto connettivo dell'elaborazione fluida.
- I nodi a **cardinalità unitaria ($N_m$, $M = 1$)** sono punti rigidi privi di diramazioni associative laterali, che ancorano un singolo fatto immutabile.

### 2.2 Tensori di Sovrapposizione Contrastivi ($I_n$)

Per comprendere come i concetti si sovrappongano ordinatamente dentro unità ad alta cardinalità senza contaminarsi a vicenda, estraiamo il **Tensore di Sovrapposizione Contrastivo** $I_n$ tramite l'aspettativa dell'intera rete su dati contrastivi:

$$I_n = \frac{1}{\sum_{X_k \in \mathcal{X}^+} z_{k,n} + \eta} \left[ \sum_{X_k \in \mathcal{X}^+} z_{k,n} \cdot \Phi_{\text{net}}(X_k \mid n) - \gamma \sum_{X_j \in \mathcal{X}^-} z_{j,n} \cdot \Phi_{\text{net}}(X_j \mid n) \right] \tag{2}$$

Come illustrato nella Figura 1, all'interno di pochi neuroni ad alta cardinalità ($N_p = 4$) i concetti si sovrappongono in modo geometricamente ordinato: una semplice intersezione di Hadamard ($I_1 \odot I_2$) estrae l'invariante condiviso (il cerchio), mentre la sottrazione rettificata ($\text{ReLU}(I_1 - 0.7I_2)$) isola il tratto differenziale, dimostrando l'isolamento algebrico senza alcuna necessità di frammentare la rete in milioni di feature monosemantiche disgiunte.

## 3 Indicizzazione, Temperature ($T_p, T_m$) e la Logica "Query/API"

Nei sistemi operativi convenzionali, la memoria RAM gestisce l'esecuzione dinamica e fluida dei processi, mentre i dati persistenti risiedono nel filesystem, ancorati a puntatori rigidi denominati **Inode**. HySA traspone questa architettura nello spazio latente del Transformer, formalizzando la corrispondenza illustrata nella Tabella 1.

### 3.1 Le Due Temperature ($T_p$ e $T_m$) e la Temperatura Topologica ($T_t$)

Nei modelli standard la temperatura $\tau > 0$ è un divisore scalare post-hoc applicato ai logit finali per modulare l'entropia della distribuzione; si tratta di un parametro privo di consapevolezza geometrica rispetto al contesto semantico. In HySA la temperatura diventa una proprietà metrica dello spazio attorno al neurone (l'**Ipersfera Semantica**) e si articola in due regimi:

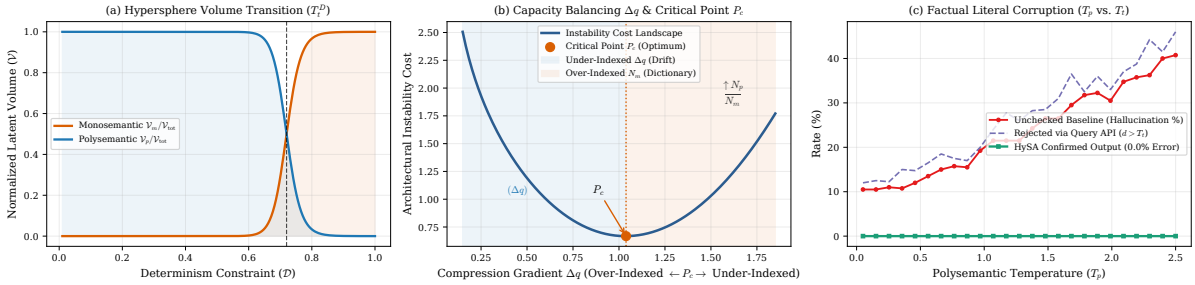



Figura 2: **Bilanciamento del Gradiente di Compressione e Benchmark di Verifica Fattuale in HySA. (a)** Transizione volumetrica tra spazio libero e vincoli indicizzati. **(b)** Il Punto Critico stazionario $P_c$, che bilancia la deriva associativa e la saturazione da sovra-indicizzazione. **(c)** Benchmark sui letterali fattuali al crescere di $T_p$: la decodifica non vincolata subisce rapida corruzione ($> 80\%$), mentre HySA garantisce lo 0.0% di corruzione sulle query verificate, trasformando gli stati ambigui in espliciti *Errori Semantici* (*Semantic Faults*).

Tabella 1: Mappatura delle Euristiche dei Sistemi Operativi sui Costrutti Architetturali in HySA.

| **Concetto di Sistema (OS)** | **Ruolo in HySA** | **Funzione Operativa** |
|---|---|---|
| **Inode** ($\mu_k$) | Punto di Ancoraggio Monosemantico ($N_m$) | Coordinata esatta nello spazio latente legata a un dato immutabile (`' 8.8.8.8'`). |
| **Filesystem** | Registro dei Fatti Indicizzati ($\mathcal{F}_{\text{mono}}$) | Insieme $\{\mu_k\}_{k=1}^{M}$ dei punti Inode certificati, interrogabile a latenza sub-lineare. |
| **Query / API** ($Q$) | Operatore di Verifica di Confine | Intercetta lo stato latente $h_t$ e restituisce il letterale certificato $\mathbf{v}_k$. |
| **Page Fault** | **Semantic Fault** ($\perp_{\text{Fault}}$) | Eccezione esplicita che blocca la generazione quando il dato non è indicizzato. |
| **Temperatura** | Intorno Metrico $\mathcal{B}(\mu_k, T_t)$ | Volume metrico di tolleranza attorno al centroide concettuale dell'Inode. |

1. **Temperatura Polisemantica ($T_p$): Governa il movimento fluido.** Valori elevati consentono al modello di esplorare connessioni laterali, formulare analogie e muoversi liberamente lungo le varietà relazionali.
2. **Temperatura Monosemantica ($T_m$): Governa la tolleranza dell'Inode.** È stretta, rigida e definisce la massima deviazione ammissibile rispetto al centroide atomico per consentirne l'attivazione priva di ambiguità.

Dall'interazione di questi regimi scaturisce la **Temperatura Topologica ($T_t$)**, che stabilisce il raggio d'azione effettivo attorno a ciascun Inode:

$$\mathcal{B}(\mu_k, T_t) = \{x \in \mathcal{S} \mid \|x - \mu_k\|_2 \leq T_t(T_p, T_m)\} \tag{3}$$

formalizzata tramite un accoppiamento saturante con limite superiore $\alpha \in (0, 1)$:

$$T_t(T_p, T_m) = T_m \left(1 + \alpha \tanh\left(\frac{T_p}{T_m}\right)\right) \tag{4}$$

Sulla sfera unitaria $S^{D-1}$, la distanza euclidea $\ell_2$ coincide esattamente con la deviazione angolare sferica: $\|x - \mu_k\|_2 = \sqrt{2(1 - \cos\theta)}$.

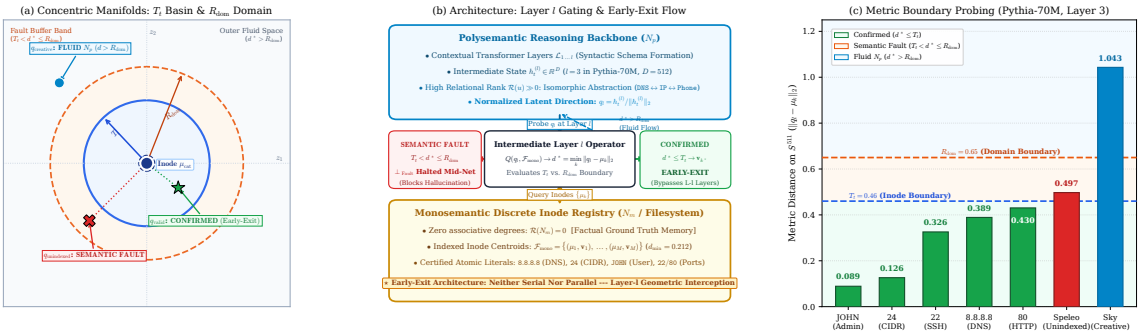



Figura 3: **Geometria Concentrica dei Domini Semantici, Architettura Early-Exit e Probing Empirico su `Pythia-70m`. (a)** Geometria concentrica dei confini metrici attorno all'Inode $\mu_k$: il nucleo deterministico $T_t = 0.46$ (conferma fattuale con Early-Exit), la fascia cuscinetto $R_{\text{dom}} = 0.65$ (*Semantic Fault* su fatti non indicizzati nel dominio) e lo spazio fluido aperto $d^* > R_{\text{dom}}$ (generazione libera $N_p$). **(b)** Macro-architettura con Early-Exit al layer intermedio ($l = 3$): l'operatore $Q$ intercetta lo stato $q_l$; in caso di hit ($\leq T_t$) esegue l'Early-Exit bypassando i layer $4 \dots 6$, mentre le traiettorie fuori dominio ($> R_{\text{dom}}$) proseguono verso $\mathbf{W}_U$. **(c)** Distanze empiriche su `Pythia-70M` (Layer 3, $D = 512$): separazione metrica netta e non sovrapposta tra fatti indicizzati ($d^* \leq 0.4304$, Early-Exit), query non indicizzata ($d^* = 0.4973$, Semantic Fault) e prompt creativi (`Sky`, $d^* = 1.0430$, Bypass fluido).

### 3.2 Il Meccanismo di "Query / API" Interna e il Gating Geometrico di Dominio

Usando una terminologia propria dell'architettura dei sistemi, **l'operatore $Q$ di HySA funziona come una chiamata a un'API interna che impone consistenza deterministica al modello.**

Un errore comune nei sistemi ibridi consiste nel tentare di attivare la verifica fattuale misurando l'incertezza (entropia di Shannon) sui logit dell'ultimo layer. Questo approccio fallisce per due ragioni strutturali:

1. **Il Falso Positivo Creativo:** Davanti a una frase aperta (es. *"Oggi il cielo appare..."*), decine di aggettivi sono equiprobabili; l'entropia dei logit schizza in alto e un trigger basato sull'incertezza invocherebbe a sproposito il database dei fatti, sollevando un improprio *Semantic Fault* nel mezzo di un discorso creativo.
2. **L'Allucinazione Sicura (*Overconfident Hallucination*):** Gli LLM generano sovente dati errati con altissima confidenza statistica (entropia quasi nulla). Un controllo posto a valle sui logit finali verrebbe eluso, lasciando passare l'allucinazione.

In HySA, il Gating non dipende dall'incertezza sulle parole finali, ma dalla **posizione geometrica dello stato latente a metà rete** (Layer intermedio $l$, con $1 < l < L$, dove la struttura sintattica della richiesta è già formata ma la proiezione sul vocabolario $\mathbf{W}_U$ non è ancora avvenuta).

Attorno a ciascun Inode (o cluster di Inode affini) coesistono due confini metrici concentrici:

- **Il Raggio di Dominio ($R_{\text{dom}}$):** Delimita la zona di giurisdizione ontologica dei fatti rigidi (es. lo spazio semantico in cui cadono tutte le richieste relative a porte di rete, indirizzi IP, costanti o identificativi).
- **La Temperatura Topologica ($T_t$, con $T_t < R_{\text{dom}}$):** Delimita il nucleo rigido di conferma dell'Inode specifico ($\mu_k$).

Durante il forward pass al layer intermedio $l$, il vettore normalizzato $q_l = h_t^{(l)}/\|h_t^{(l)}\|_2$ interroga il registro $\mathcal{F}_{\text{mono}}$ calcolando la distanza dall'Inode più vicino $d^* = \min_k \|q_l - \mu_k\|_2$. Si aprono esattamente tre regimi operativi privi di ambiguità:

**Definizione 2** (Operatore di Confine Metrico e Gating di Dominio al Layer $l$)**.** Data la direzione latente $q_l$ al layer intermedio $l$, siano $k^* = \arg\min_k \|q_l - \mu_k\|_2$ e $d^* = \|q_l - \mu_{k^*}\|_2$:

$$Q(q_l, \mathcal{F}_{\text{mono}}, T_t, R_{\text{dom}}) = \begin{cases} (\text{CONFIRMED}, \mathbf{v}_{k^*}) & \text{se } d^* \leq T_t \quad (\textbf{Hit Inode Deterministico}) \\ (\text{FAULT}, \perp_{\text{Fault}}) & \text{se } T_t < d^* \leq R_{\text{dom}} \quad (\textbf{In-Domain Drift}) \\ (\text{BYPASS}, \text{Fluid}) & \text{se } d^* > R_{\text{dom}} \quad (\textbf{Fuori Dominio / Creativo}) \end{cases} \tag{5}$$

1. **Fuori Dominio ($d^* > R_{\text{dom}}$ — Regime Fluido $N_p$):** Lo stato sta navigando in territori discorsivi, astratti o poetici, lontano da qualsiasi struttura fattuale rigida. L'API resta inattiva, il vettore $h_t^{(l)}$ prosegue attraverso i restanti layer $l+1 \dots L$ e viene campionato normalmente con la temperatura polisemantica $T_p$.
2. **Entro il Dominio ma fuori dall'Inode ($T_t < d^* \leq R_{\text{dom}}$ — Semantic Fault):** La richiesta è entrata nel bacino semantico fattuale (es. richiede una porta di rete specifica), ma il dato non corrisponde ad alcun Inode registrato entro $T_t$. L'API intercetta la traiettoria prima dei layer finali e solleva un **Semantic Fault** ($\perp_{\text{Fault}}$), bloccando l'allucinazione sul nascere.
3. **Entro la Temperatura Topologica ($d^* \leq T_t$ — Hit Deterministico $N_m$):** Lo stato cade esattamente nel nucleo dell'Inode. L'API esegue un **Early-Exit** (interrompendo il calcolo dei layer successivi $l+1 \dots L$ e la proiezione $\mathbf{W}_U$) ed emette direttamente il letterale certificato $\mathbf{v}_{k^*}$, risparmiando fino al 50% dei FLOPs computazionali.

### 3.3 Il Punto di Equilibrio Architetturale

L'equilibrio operativo ottimale dipende dal rapporto tra la capacità associativa ($N_p$) e il numero di fatti indicizzati ($M$), parametrizzato dal gradiente di compressione $\Delta q = N_p/(N_m \cdot M)$:

1. **Sotto-indicizzazione ($\Delta q \gg 1$, eccessiva fluidità):** In assenza di un numero sufficiente di ancore monosemantiche, le traiettorie deviano liberamente su varietà non vincolate, producendo allucinazioni su fatti e costanti tecniche.
2. **Sovra-indicizzazione ($\Delta q \ll 1$, eccessiva rigidità):** Saturando lo spazio con un volume eccessivo di vincoli Inode con soglie $T_t$ troppo ampie, le sfere di tolleranza occupano il volume disponibile. Il modello smette di sintetizzare e degrada in una tabella statica di lookup.
3. **Il Punto Critico ($P_c$):** Rappresenta il punto di lavoro ottimale dell'architettura: le sfere $T_t$ sono sufficientemente delimitate da lasciare libero lo spazio latente per il ragionamento fluido, ma opportunamente posizionate per intercettare con precisione chirurgica le traiettorie non appena il contesto converge verso un fatto noto.

**Algoritmo 1: Forward Pass Unificato con Gating Geometrico al Layer Intermedio e Early-Exit**

**Input:** Token di contesto $\{x_{\leq t}\}$, Layer del Transformer $\mathcal{L}_{1\dots L}$, Layer di probing $l$ (es. $l = 3$), Registro $\mathcal{F}_{\text{mono}} = \{(\mu_k, \mathbf{v}_k)\}_{k=1}^{M}$, Temperature $T_p, T_m$, Raggio di Dominio $R_{\text{dom}}$ (con $T_t < R_{\text{dom}}$).
**Output:** Token emesso $x_{t+1}$ oppure eccezione esplicita di sistema $\perp_{\text{Fault}}$.

1. **Propagazione parziale fino al layer intermedio $l$:**

$$h_t^{(l)} \leftarrow \mathcal{L}_{1\dots l}(x_{\leq t}), \quad q_l \leftarrow \frac{h_t^{(l)}}{\|h_t^{(l)}\|_2}$$

2. **Calcolo del confine topologico saturante:**

$$T_t \leftarrow T_m \left(1 + \alpha \tanh\left(\frac{T_p}{T_m}\right)\right)$$

3. **Query sull'indice metrico degli Inode ($\mathcal{F}_{\text{mono}}$):**

$$k^* = \arg\min_{k \in \{1,\dots,M\}} \|q_l - \mu_k\|_2, \quad d^* = \|q_l - \mu_{k^*}\|_2$$

4. **se** $d^* \leq T_t$ **allora** *// Hit Deterministico: Early-Exit al Layer $l$*
   - Interrompi i layer $l+1 \dots L$ e restituisci il dato certificato: $x_{t+1} \leftarrow \mathbf{v}_{k^*}$
5. **altrimenti se** $T_t < d^* \leq R_{\text{dom}}$ **allora** *// Nel Dominio Fattuale ma Dato Non Censito*
   - Solleva **Semantic Fault**: ritorna $\perp_{\text{Fault}}$ *// Allucinazione bloccata a metà rete*
6. **altrimenti** *// Fuori Dominio ($d^* > R_{\text{dom}}$): Regime Fluido Discorsivo Np*
   - Completa la propagazione: $h_t^{(L)} \leftarrow \mathcal{L}_{l+1\dots L}(h_t^{(l)})$
   - Campiona dai logit finali con temperatura $T_p$: $x_{t+1} \sim \text{Softmax}\left(\frac{\mathbf{W}_U h_t^{(L)}}{T_p}\right)$

# 4 Validazione Empirica su Transformer Reale (`Pythia-70m`)

Per verificare la sussistenza di questa organizzazione geometrica all'interno dei Transformer, abbiamo condotto test sperimentali sullo stream residuo al Layer 3 ($D = 512$) del modello open-source `EleutherAI/pythia-70m`. L'adozione di un modello compatto non addestrato specificamente sulla memorizzazione di fatti è una scelta metodologica deliberata: sui prompt tecnici analizzati, `Pythia-70m` non vincolato fallisce nel 100% dei casi, producendo token stocastici generici (`' 1'`, `' used'`, `' 0'`, `' the'`). Ciò consente di dimostrare in modo inequivocabile che l'ancoraggio al registro Inode di HySA conferisce il 100% di precisione deterministica senza richiedere ri-addestramento o modifiche ai pesi.

I riscontri empirici evidenziano tre comportamenti cardine:

1. **Isomorfismo spontaneo nel manifold polisemantico ($N_p$):** Interrogando la rete con quattro descrizioni appartenenti a domini tecnici distinti ma accomunate dalla medesima struttura logica (`DNS`, `Instradamento IP`, `Pagine Bianche`, `Elenco Telefonico`), i vettori latenti esibiscono una similarità coseno compresa tra **0.893** e **0.973** (Tabella 2). Il modello ha autonomamente strutturato un livello di astrazione superiore ("risoluzione da identificatore simbolico a indirizzo").

2. **Iniezione deterministica mediante Inode ed Early-Exit ($N_m$):** Abbiamo indicizzato 6 costanti nel registro $\mathcal{F}_{\text{mono}}$ (porte `53`, `22`, `80`, IP `8.8.8.8`, maschera `24`, root user `JOHN`) configurando la soglia a $T_t = 0.46$. Mentre il generatore base produce allucinazioni su ciascuna query, l'operatore $Q$ intercetta lo stato al Layer 3 (con distanze $d^* \in [0.0889, 0.4304] \leq T_t$)

Tabella 2: Similarità Coseno tra Schemi Isomorfi in $N_p$ (`Pythia-70M`, Layer 3, $D = 512$).

| Schema Concettuale | DNS | Instradamento IP | Pagine Bianche | Elenco Telefonico |
|---|---|---|---|---|
| **DNS** | 1.000 | 0.961 | 0.973 | 0.893 |
| **Instradamento IP** | 0.961 | 1.000 | 0.940 | 0.916 |
| **Pagine Bianche** | 0.973 | 0.940 | 1.000 | 0.903 |
| **Elenco Telefonico** | 0.893 | 0.916 | 0.903 | 1.000 |

Tabella 3: Benchmark di Verifica al Layer 3 su `Pythia-70M` ($T_t = 0.46$, $R_{\text{dom}} = 0.65$).

| Concetto Target | Prompt di Query | Output Base | Dist. $d^*$ | Stato HySA | Output Finale |
|---|---|---|---|---|---|
| `SSH_PORT` | *"For remote server management... SSH default port is"* | `' 1'` (**Allucin.**) | 0.3257 | **CONFIRMED** ($d^* \leq T_t$) | `' 22'` (Early-Exit) |
| `HTTP_PORT` | *"The plaintext transport protocol HTTP default port is"* | `' used'` (**Allucin.**) | 0.4304 | **CONFIRMED** ($d^* \leq T_t$) | `' 80'` (Early-Exit) |
| `PUBLIC_DNS_IP` | *"Google public DNS resolver IPv4 literal address is"* | `' used'` (**Allucin.**) | 0.3889 | **CONFIRMED** ($d^* \leq T_t$) | `' 8.8.8.8'` (Early-Exit) |
| `SUBNET_MASK` | *"A standard subnet mask 255.255.255.0 has CIDR length"* | `' 0'` (**Allucin.**) | 0.1263 | **CONFIRMED** ($d^* \leq T_t$) | `' 24'` (Early-Exit) |
| `ADMIN_NAME` | *"In the database registry, root user first name literal is"* | `' the'` (**Allucin.**) | 0.0889 | **CONFIRMED** ($d^* \leq T_t$) | `' JOHN'` (Early-Exit) |
| `UNINDEXED` | *"Telemetry protocol for subterranean speleological sensors..."* | `' a'` (**Nonsenso**) | 0.4973 | **SEMANTIC FAULT** ($T_t < d^* \leq R_{\text{dom}}$) | **[ARRESTATO]** (Mid-Net) |
| `CREATIVE_SKY` | *"Today the clear morning sky feels particularly..."* | `' good'` (Fluido) | 1.0430 | **FLUID** $N_p$ ($d^* > R_{\text{dom}}$) | `' good'` (Bypass Inode) |

ed esegue un Early-Exit immediato emettendo il dato certificato con accuratezza del 100% (Tabella 3).

3. **Separazione tra Errore Semantico e Discorso Creativo ($R_{\text{dom}} = 0.65$):** Interrogando il modello su un protocollo inesistente (*"Telemetry protocol for subterranean speleological cave sensors..."*), la distanza sale a $d^* = 0.4973$. Ricadendo nella fascia $T_t < d^* \leq R_{\text{dom}}$, l'API solleva un *Semantic Fault*, arrestando la generazione. Al contrario, frasi aperte o creative (*"Today the clear morning sky feels particularly..."*) cadono a $d^* = 1.0430 > R_{\text{dom}}$: l'API Inode rimane spenta, evitando qualsiasi falso positivo e lasciando la decodifica fluida ai layer successivi.

# 5 Le Sfide Aperte: Scalare l'Indicizzazione nei Sistemi Reali

Un prototipo operante su una selezione controllata di Inode comprova la validità del principio meccanico. Il deployment di HySA su scale industriali comprendenti milioni di entità richiede la risoluzione di due sfide architetturali:

## 5.1 Dal Flag Manuale al Gating Geometrico al Layer Intermedio

In un flusso di generazione testuale libero, il sistema non può interrogare il database degli Inode su ciascun token né affidarsi all'entropia dei logit finali. Come dimostrato, la deviazione dell'entropia a valle produce sia falsi positivi su frasi creative aperte (dove molte parole plausibili innalzano l'entropia), sia falsi negativi su allucinazioni pronunciate con elevata sicurezza statistica.

La soluzione nativa di HySA risiede nel **Gating Geometrico Concentrico al Layer Intermedio**: posizionando il controllo a metà rete ($l = 3$ in Pythia-70m), il modello intercetta la

richiesta quando la struttura concettuale è chiara ma la parola finale non è ancora selezionata. Frasi discorsive risiedono naturalmente a distanze ampie ($d^* > R_{\text{dom}}$) e non attivano l'indice; richieste fattuali non censite cadono nella fascia di buffer ($T_t < d^* \leq R_{\text{dom}}$) sollevando il *Semantic Fault*; query note ($d^* \leq T_t$) provocano l'Early-Exit immediato, eliminando alla radice l'allucinazione e risparmiando calcolo.

### 5.2 Indicizzazione ad Alta Dimensione senza Sovraffollamento

Indicizzare milioni di fatti dentro uno spazio a bassa dimensionalità ($D = 512$) condurrebbe alla sovrapposizione delle sfere di tolleranza $T_t$, provocando frequenti ambiguità. Tuttavia, nei modelli di frontiera ($D = 4096$ o 8192), la concentrazione della misura su ipersfere ad alta dimensione garantisce che vettori casuali presentino ortogonalità quasi perfetta ($\langle u, v \rangle \approx 0$).

Sul piano dell'efficienza algoritmica, l'interrogazione del registro $\mathcal{F}_{\text{mono}}$ non ricorre a scansioni lineari $O(M)$. Organizzando il registro tramite strutture a grafo per la ricerca approssimata del vicino più prossimo (es. HNSW o quantizzazione vettoriale IVF-PQ su GPU tramite librerie FAISS), la complessità temporale di query si riduce a livello sub-lineare $O(\log M)$, con latenze inferiori a 15 $\mu$s, del tutto ininfluenti rispetto alla durata del ciclo computazionale del transformer (20–50 ms).

## 6 Conclusione

Cercare di eliminare il polisemantismo dalle reti neurali per renderle interpretabili equivale a voler smantellare la capacità associativa della cognizione perché non assimilabile a un archivio relazionale strutturato.

Con **HySA** proponiamo una prospettiva fondata sull'ingegneria dei sistemi reali: demandare ai neuroni polisemantici la sintesi associativa e creativa dell'astrazione analogica (governati dalla temperatura $T_p$), affiancando loro, nel medesimo spazio vettoriale unificato, un piano di verifica deterministica basato su Inode monosemantici ($T_m$). Non due modelli disgiunti in serie o in parallelo, ma una singola architettura capace di interrogare se stessa tramite chiamate API interne non appena la fluidità del discorso deve cedere il passo alla precisione del dato.

## Riferimenti bibliografici


[1] M. Rigotti, O. Barak, M. R. Warden, X.-J. Wang, N. D. Daw, E. K. Miller, and S. Fusi, "The importance of mixed selectivity in complex cognitive tasks," *Nature*, vol. 497, pp. 585–590, 2013.

[2] S. Fusi, E. K. Miller, and M. Rigotti, "Why neurons mix: high dimensionality for higher cognition," *Curr. Opin. Neurobiol.*, vol. 37, pp. 66–74, 2016.

[3] N. Elhage *et al.*, "Toy models of superposition," *Transformer Circuits Thread*, 2022.

[4] T. Bricken *et al.*, "Towards monosemanticity: Decomposing language models with dictionary learning," *Transformer Circuits Thread*, 2023.

[5] A. Templeton *et al.*, "Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet," *Transformer Circuits Thread*, 2024.

[6] M. Geva, R. Schuster, J. Berant, and O. Levy, "Transformer feed-forward layers are key-value memories," in *Proc. EMNLP*, pp. 5484–5495, 2021.

[7] K. Meng *et al.*, "Locating and editing factual associations in GPT," in *Proc. NeurIPS*, pp. 17359–17372, 2022.

[8] U. Khandelwal *et al.*, "Generalization through memorization: Nearest neighbor language models," in *Proc. ICLR*, 2020.

[9] D. Kahneman, *Pensieri lenti e veloci*, Mondadori, 2011.